



Universidad Tecnológica de La Habana
Facultad de Ingeniería en Telecomunicaciones y
Electrónica

**“Diseño de un sistema de medición con sensor
espectroscópico para detectar adulterantes en la leche”**

Centro de Investigaciones de Microelectrónica (CIME)

MIPYME AlaSoluciones

Tesis en opción al título académico de Ingeniero en Telecomunicaciones y
Electrónica

Autor: Reysel Cepero Ruíz

La Habana, 2023



Universidad Tecnológica de La Habana
Facultad de Ingeniería en Telecomunicaciones y
Electrónica

**“Diseño de un sistema de medición con sensor
espectroscópico para detectar adulterantes en la leche”**

Autor: Reysel Cepero Ruíz

Tutor: Ing. Jonathan Raidel Valdés Alfonso

La Habana, 2023

“Diseño de un sistema de medición con sensor espectroscópico para detectar adulterantes en la leche”

PENSAMIENTO

"El verdadero progreso es el que pone la tecnología al alcance de todos"

Henry Ford.

DECLARACIÓN DE AUTORIDAD

El autor de este trabajo de diploma declara que el presente constituye el resultado de su propio trabajo y esfuerzo. Las ideas tomadas de otros documentos han sido correctamente referenciadas mediante la bibliografía empleada, de acuerdo con la política internacional establecida para esto. Por cuanto, se autoriza a que el Departamento de Telecomunicaciones y Telemática, de la Facultad de Telecomunicaciones y Electrónica de la Universidad Tecnológica de La Habana José Antonio Echevarría, utilice el mismo para los fines que estime conveniente, con la debida referencia a su autor.

Para que así conste, firman la presente:

Reysel Cepero Ruíz

Autor

Ing. Jonathan Raidel Valdés Alfonso

Tutor

DEDICATORIA

Este trabajo está dedicado a toda mi familia que siempre me apoyó durante el camino de mi formación académica.

AGRADECIMIENTOS

A mis padres Olga Lidia y Reinaldo, mi hermana Yilena, por apoyarme incondicionalmente a lo largo de toda mi vida incluyendo mi carrera universitaria.

A mi novia Glenda por apoyarme en todas mis metas.

A mis hermanos Franny y Margarita de los que siempre he tenido ayuda en todo momento.

A mis abuelos Sonia, José Luis y Pura por haber sido un pilar fundamental de mi crecimiento académico.

A todos mis tíos especialmente Jorge Luis, Elisabeth, Osvaldo, Clara que siempre han estado al tanto y brindando ayuda en mis estudios de ingeniería.

A mi tutor Jonathan por haber sido un excelente profesor, brindarme su apoyo y conocimiento para ayudarme a crecer como ingeniero.

A mis amigos Roidel, Alejandro, Amador, Neisser, José Manuel, Lauren, Yosdalys y otros que formaron parte de tantas noches de estudios y anécdotas que serán inolvidables.

RESUMEN

La adulteración de la leche es un problema que afecta a muchas regiones del mundo. Este fenómeno implica agregar sustancias no permitidas o diluir la leche con agua, con el fin de obtener mayores ganancias económicas. Esta práctica compromete la calidad y la seguridad de la leche, ya que puede tener efectos nocivos para la salud humana. El objetivo de este trabajo es desarrollar un sistema de medición de bajo costo para la detección de adulterantes en la leche en tiempo real, de esta manera contribuir a la seguridad alimentaria y a la calidad de los productos lácteos en la industria. Para la detección multivariable se empleó el método espectroscópico utilizando el sensor AS7265x, que entrega 18 canales y cubre el espectro visible e infrarrojo cercano (NIR) en un rango de 410 nm a 940 nm. La unidad central del sistema propuesto es la Raspberry Pi 3b. Esta se encarga de levantar la página web utilizando Flask, desde la cual se pueden realizar las predicciones y acceder a registros que contienen información de las mismas, mediante una red Ethernet. Esta recibe los datos de las mediciones del sensor mediante el protocolo I2C y ejecuta los algoritmos de Python que procesan los datos, realizan el Análisis de Componentes Principales, el Análisis Discriminante Lineal y finalmente las predicciones. Para entrenar y probar la efectividad del clasificador se realizaron dos grupos de muestras. El primero corresponde a cuatro muestras de disoluciones de leche en polvo con distintas concentraciones de agua y la quinta agua solamente. El segundo grupo se conformó por cuatro muestras de leche de vaca con distintas concentraciones de agua y la quinta agua solamente. Se obtuvo un promedio de acierto en las predicciones de las muestras del primer grupo de 96.77% y en las del segundo 99.47%.

ABSTRACT

The adulteration of milk is a problem that affects many regions of the world. This phenomenon involves adding unauthorized substances or diluting the milk with water in order to obtain higher economic gains. This practice compromises the quality and safety of milk, as it can have harmful effects on human health. The objective of this work is to develop a low-cost measurement system for real-time detection of adulterants in milk, thereby contributing to food safety and the quality of dairy products in the industry. For multivariable detection, the spectroscopic method was employed using the AS7265x sensor, which provides 18 channels and covers the visible and near-infrared (NIR) spectrum in a range from 410 nm to 940 nm. The central unit of the proposed system is the Raspberry Pi 3b, which is responsible for hosting the web page using Flask. From this web page, predictions can be made and access can be gained to records containing information about them through an Ethernet network. It receives data from the sensor measurements via the I2C protocol and runs Python algorithms that process the data, perform Principal Component Analysis, Linear Discriminant Analysis, and finally make predictions. To train and test the effectiveness of the classifier, two groups of samples were used. The first group consisted of four samples of powdered milk solutions with different concentrations of water and the fifth one containing only water. The second group was composed of four samples of cow's milk with different concentrations of water and the fifth one containing only water. The average prediction accuracy obtained for the samples in the first group was 96.77%, and for the samples in the second group, it was 99.47%

GLOSARIO DE TÉRMINOS

- NC 448:2006: Norma cubana de especificaciones de calidad para leche cruda.
- NIR: Near Infrared (Infrarrojo Cercano). Se refiere al rango de longitud de onda de la luz infrarroja que es cercana al espectro visible.
- HPLC: High-Performance Liquid Chromatography (Cromatografía Líquida de Alta Resolución). Es una técnica utilizada para separar, identificar y cuantificar componentes en una muestra líquida.
- UV: Ultraviolet (Ultravioleta). El rango de radiación electromagnética con longitudes de onda más cortas que la luz visible,
- SVM: Support Vector Machines (Máquinas de Vectores de Soporte). Son algoritmos de aprendizaje automático utilizados para la clasificación y regresión de datos.
- SBC: Single Board Computers (Computadoras de Placa Única). Son computadoras completas en una sola placa, que incluyen procesador, memoria, puertos de entrada/salida, etc.
- S11639: (Sensor Hamamatsu S11639). Es un sensor de imagen desarrollado por Hamamatsu Photonics, utilizado para la detección de luz en diferentes aplicaciones.
- FWHM: Full Width at Half Maximum (Ancho Total a Mitad del Máximo). Es una medida utilizada para describir la anchura de una curva de distribución o un pico en una gráfica.
- PCA: Principal Component Analysis (Análisis de Componentes Principales). Es una técnica utilizada para reducir la dimensionalidad de los datos y encontrar patrones en ellos.
- LDA: Linear Discriminant Analysis (Análisis de Discriminante Lineal). Es una técnica utilizada para la clasificación de datos en función de sus características.
- ROB: Robust Outlier Analysis (Análisis Robusto de Valores Atípicos) Análisis de valores atípicos robustos. Es una técnica utilizada para identificar valores atípicos en un conjunto de datos.
- MRA: Multivariate Regression Analysis (Análisis de Regresión Multivariante). Análisis de regresión multivariante. Es una técnica

utilizada para analizar las relaciones entre múltiples variables de un conjunto de datos.

ÍNDICE GENERAL

INTRODUCCIÓN	1
CAPÍTULO I – “ESTADO DEL ARTE Y REVISIÓN BIBLIOGRÁFICA”	5
1.2 Estado actual de la agricultura en Cuba:	5
1.3 La leche, beneficios e importancia:	5
1.4 Adulteración de la leche:	6
1.5 Técnicas para detectar adulterantes:	7
1.6 Espectroscopia	8
1.6.1 Espectroscopía ultravioleta-visible (UV-VIS):	11
1.6.2 Espectroscopía infrarroja cercana (NIR):	12
1.7 Análisis del estado del arte referente a temática:	13
1.7.1 Tabla comparativa de la bibliografía estudiada	19
1.8 Equipos comerciales utilizados en la detección de adulterantes	20
1.9 Conclusiones del capítulo	21
CAPÍTULO II – “MATERIALES Y MÉTODOS”	23
2.1 Hardware empleado	23
2.1.1 Microordenadores “Computadoras de placa única”	23
2.1.2 Raspberry Pi 3b	24
2.1.3 Sensores espectroscópicos	27
2.1.4 Sensor AS7265x	28
2.2 Software empleado	29
2.2.1 Python	29
2.2.2 Flask	30
2.3 Métodos de detección multivariable	32
2.3.1 Análisis de Componentes Principales (PCA)	34
2.3.2 Análisis Discriminante Lineal (LDA)	35
2.3.3 Combinación de PCA y LDA	38

2.4 Conclusiones del capítulo	39
CAPÍTULO III – “DISEÑO E IMPLEMENTACIÓN DEL SISTEMA”	41
3.1 Diseño del sistema general.....	41
3.2 Diseño de Hardware	42
3.3 Diseño del Firmware	45
3.4 Diseño de la página	47
3.5 Preparación de las muestras para las mediciones de entrenamiento.....	52
3.6 Análisis de los resultados obtenidos	55
3.6.1 Selección del número de componentes principales óptimo para reducir la dimensionalidad de los datos.	56
3.6.2 Aplicación de PCA en los datos para entrenamiento	59
3.6.3 Aplicación de LDA a los datos procesados con PCA.....	60
3.6.4 Cálculo de la precisión del clasificador.....	62
3.6.5 Comprobación de los resultados obtenidos en la realización de predicciones utilizando muestras conocidas.	63
3.7 Conclusiones del capítulo	65
CAPÍTULO IV – “ANÁLISIS ECONÓMICO Y DE VIABILIDAD DEL PROYECTO”	67
4.1 Cálculo de los costos de resultados de la investigación	67
4.1.1 Cálculo del costo directo	67
4.1.1.1 Salario básico	67
4.1.1.2 Salario Complementario	68
4.1.1.3 Seguridad social	69
4.1.1.4 Gastos por medios o materiales directos.....	69
4.1.1.5 Dietas y pasajes	70
4.1.1.6 Otros gastos	70
4.1.2 Cálculo del costo indirecto	70

4.2 Precio de los servicios científico-técnico y de los resultados de la investigación	71
4.3 Análisis de la factibilidad e impacto de los resultados.....	72
4.4 Conclusiones del Capítulo	74
CONCLUSIONES GENERALES	76
RECOMENDACIONES	78

ÍNDICE DE TABLAS

Tabla 1: Comparación de la bibliografía estudiada	19
Tabla 2: Comparación de equipos comerciales para la detección de adulterantes en la leche.	20
Tabla 3: Especificaciones de la Raspberry Pi 3b	26
Tabla 4: Precio de los componentes de Hardware del detector diseñado	69

ÍNDICE DE FIGURAS

Figura 1: Espectro electromagnético.	9
Figura 2: Radiación absorbida por una muestra.....	10
Figura 3: Espectro electromagnético ultravioleta-visible (UV-VIS).	11
Figura 4: Rango de longitud de onda que ocupa la espectroscopia NIR en el espectro electromagnético.	12
Figura 5: El sistema de sensor multiespectral habilitado por IA.	14
Figura 6: Sistema diseñado para la lectura de nitrógeno en las hojas.	15
Figura 7: Adquisición de los datos.	16
Figura 8: Ejemplos de placas SBC.	24
Figura 9: Raspberry Pi 3 Modelo B y sus elementos fundamentales.	25
Figura 10: Sensor de espectroscopía SparkFun Triad - AS7265x.....	28
Figura 11: Vista principal la página del detector espectroscópico de adulterantes en la leche.	48
Figura 12: Opción de la página web que permite realizar una predicción en tiempo real.....	49
Figura 13: Campo de búsqueda en la tabla que registra las mediciones del detector espectroscópico de adulterantes en la leche.....	49

Figura 14: Tabla que registra los datos de una medición realizada por el detector espectroscópico de adulterantes en la leche.....	50
Figura 15: Vista de la página que muestra la lista con los gráficos de las mediciones realizadas.....	50
Figura 16: Espectro y resultado de predicción almacenado de una muestra ...	51
Figura 17: Opción de la página web del detector de adulterantes que permite realizar mediciones para entrenar el sistema	52
Figura 18: Frasco utilizado para las mediciones del Grupo A.....	53
Figura 19: Medición bajo luz artificial en la habitación.....	54
Figura 20 Frasco utilizado para las mediciones del Grupo B	55
Figura 21: Medición sin luz en la habitación.....	55
Figura 22: Datos que se ingresaron para la realización de una muestra de leche pura del Grupo A.....	63
Figura 23: Resultado de la predicción y espectro de la muestra analizada del Grupo A.	64
Figura 24: Datos que se ingresaron para la realización de una muestra de leche pura del Grupo B.....	65
Figura 25 Resultado de la predicción y espectro de la muestra analizada del Grupo B.....	65

ÍNDICE DE GRÁFICOS

Gráfico 1: Las dimensiones de la varianza máxima (PCA1 y PCA2) como resultado de PCA.	35
Gráfico 2: Dos clases distintas de un grupo de datos	36
Gráfico 3: Proyección de los datos en el nuevo eje.....	37
Gráfico 4 Nuevo eje como resultado de aplicar LDA.....	37
Gráfico 5: Concentración de las muestras del Grupo A.....	53
Gráfico 6: Concentración de las muestras del Grupo B.....	54

Gráfico 7: Varianza explicada y varianza acumulada de los datos (a la izquierda) y los datos derivados (a la derecha) del Grupo A.	57
Gráfico 8: Varianza explicada y varianza acumulada de los datos (a la izquierda) y los datos derivados (a la derecha) del Grupo B.	57
Gráfico 9: Varianza acumulada de los datos del Grupo A.	58
Gráfico 10: Varianza acumulada de los datos del Grupo B.	59
Gráfico 11: mediciones de entrenamiento del Grupo A después de aplicar PCA.	59
Gráfico 12: Mediciones de entrenamiento del Grupo B después de aplicar PCA.	60
Gráfico 13: Clases del Grupo A después de aplicar LDA.	61
Gráfico 14 Clases del Grupo B después de aplicar LDA.	61
Gráfico 15: Efectividad en las predicciones del Grupo A y Grupo B.	62

ÍNDICE DE ESQUEMAS

Esquema 1: Combinación de PCA y LDA.	39
Esquema 2: Diseño general del detector espectroscópico de adulterantes en la leche.	41
Esquema 3: Hardware del detector espectroscópico de adulterantes en la leche.	42
Esquema 4: Funcionamiento del sensor AS7265X.	44
Esquema 5: Funcionamiento del firmware del detector espectroscópico de adulterantes en la leche.	45
Esquema 6: Funcionamiento de la página web del detector espectroscópico de adulterantes en la leche.	48

INTRODUCCIÓN

Situación Problema:

La ganadería en Cuba es una actividad de elevada importancia que proporciona alimentos, empleos y beneficios económicos a un nivel local y nacional. Actualmente en el país se han adoptado una serie de medidas con el fin de garantizar su sostenibilidad y crecimiento, dentro de las que se encuentran la vinculación de la ciencia y la tecnología al sector.

La leche, el queso y otros productos lácteos son algunos de los alimentos de producción agrícola más consumidos, por más de 600 millones de personas en todo el mundo, en su mayoría de países desarrollados[1]. La leche está hecha principalmente de agua y contiene macronutrientes como: proteínas, grasas, vitaminas (vitamina D, riboflavina) y minerales (potasio, fósforo) en proporciones significativas, lo que ayuda a proporcionar una dieta saludable en los humanos[2]. Con el fin de obtener ganancias adicionales, la adulteración de la leche es un escenario común entre los comerciantes, los productos utilizados en este proceso a largo plazo resultan nocivos para la salud[3].

En Cuba los puntos de venta no cumple con los requisitos mínimos establecidos en la norma de especificaciones de calidad para leche cruda NC 448:2006[4]. En las muestras de leche analizadas, se reportan resultados inferiores de 3,20g%, 2,90g%, 8,20g% y 11,40g% para grasa, proteínas, sólidos totales y sólidos no grasos respectivamente. Esta disminución de la calidad de la leche en el punto de venta se debe, fundamentalmente, a las adulteraciones por aguado. La leche no es un sistema en equilibrio debido a las variaciones, las reacciones químicas y los cambios biológicos que ocurren en su composición, por lo que la adulteración con agua provoca cambios en su calidad composicional[5].

Dado la importancia de este producto, la detección de adulterantes es una investigación necesaria y significativa. Los métodos para la detección de estos adulterantes se realizan en laboratorios con equipos costosos y requieren el transporte de las muestras hacia los mismos lo que dificulta su ejecución. Esto

podría solucionarse realizando un sistema de medición manual, que facilite su uso a los productores y comercializadores.

Problema a resolver:

Diseñar un sistema de bajo costo para la detección de adulterantes en la leche usando un sensor espectroscópico y una Raspberry Pi, que permita mostrar los resultados obtenidos al usuario en una página web.

Objetivo general:

Desarrollar un sistema de medición de bajo costo para la detección de adulterantes en la leche en tiempo real.

Objetivos específicos:

- Revisión bibliográfica sobre la adulteración de la leche y las técnicas espectroscópicas para la detección de adulterantes.
- Estudio de las características y especificaciones del sensor AS7265x y su integración con la Raspberry Pi.
- Estudio del lenguaje de programación Python.
- Familiarización con el sistema operativo Linux.
- Diseñar y el sistema de medición y el software de control correspondiente.
- Evaluar el sistema de medición para determinar su eficiencia en la detección de adulterantes en la leche.
- Realizar el análisis e interpretación de los resultados obtenidos.
- Desarrollar un análisis del costo del proyecto.
- Elaborar el documento de tesis.

Hipótesis:

Es posible desarrollar un sistema de medición de bajo costo con un sensor espectroscópico basado en Raspberry Pi y el sensor AS7265x que permita detectar adulterantes en la leche.

Métodos de trabajo:

Métodos teóricos

- Método hipotético-deductivo: Se caracteriza por establecer una hipótesis de solución del problema fundamentada en la literatura internacional especializada. Se desarrolló la investigación fundamentada en la hipótesis planteada y se va corrigiendo esta, según los resultados alcanzados hasta lograr el cumplimiento de los objetivos y la solución del problema ingenieril planteado.
- Método sistémico- estructural- funcional: Se utilizó para desarrollar el objeto de estudio (sistema de medición con sensor espectroscópico). Determinar la estructura del sistema, identificando sus componentes y la relación entre ellos, para entender su funcionamiento de manera completa.
- Método de análisis y síntesis: Permite fraccionar en partes y componentes el estudio de un problema o proceso físico desconocido. Posibilita la definición de conclusiones parciales que posteriormente se sistematizan en un conocimiento más general, logrando la síntesis de los aspectos más generales o específicos del problema a resolver.

Métodos empíricos

- Método de modelación y simulación: Permite modelar virtualmente las soluciones planteadas en el problema investigativo. Esto se pone en práctica cuando se realiza la simulación de los datos para entrenar la red neuronal.
- Análisis documental: Se realizó una revisión bibliográfica exhaustiva sobre el tema, para conocer las características del sensor espectroscópico, su funcionamiento y las posibilidades de uso.

Estructura del contenido:

El contenido del presente trabajo se divide en las siguientes secciones: Introducción, Capítulos (del 1 al 4), Conclusiones, Recomendaciones,

Referencias bibliográficas y Bibliografía consultada. A continuación, se muestra un breve resumen del contenido de los principales apartados (Introducción y Capítulos).

- **Introducción: Diseño de la investigación**

En este apartado se presentan una introducción a la temática a tratar y los aspectos correspondientes al diseño de la investigación (Situación problema, Problema a resolver, Hipótesis, Objetivo general, Objetivos específicos y Métodos de trabajo).

- **Capítulo 1: Estado del arte y revisión bibliográfica.**

En este capítulo se realiza un análisis histórico-lógico de los sistemas de detección de adulterantes y una revisión bibliografía del estado actual de la temática.

- **Capítulo 2: Materiales y métodos.**

Este capítulo está dedicado a la descripción de los materiales y métodos empleados, además del estudio y caracterización de los métodos de predicciones de adulterantes en alimentos.

- **Capítulo 3: Diseño e implementación del sistema.**

Este capítulo está dedicado a la implementación del sistema de adquisición, el algoritmo de predicción en la Raspberry Pi y la valoración de los resultados, así como el diseño de la interfaz de usuario.

- **Capítulo 4: Análisis económico y de viabilidad del proyecto.**

Este capítulo está dedicado al análisis técnico-económico del proyecto. Se hace una estimación de costo del diseño y se plantean los beneficios aportados.

CAPÍTULO I – “ESTADO DEL ARTE Y REVISIÓN BIBLIOGRÁFICA”

El surgimiento de la agricultura durante el Neolítico transformó la historia y la supervivencia humana. La agricultura, como base de la producción de alimentos, introdujo en la humanidad cambios importantes como el sedentarismo y la formación de mayores poblaciones, marcando por completo el desarrollo de la historia. En los primeros pueblos, los seres humanos comenzaron a cuidar a los animales y cultivar las plantas sin necesidad de recolectarlas. Esto junto a la utilización de herramientas provocó una revolución completa que marcó el fin de una época basada en la recolección y la caza y dio comienzo de la agricultura y la ganadería como modo de vida[6].

1.2 Estado actual de la agricultura en Cuba:

La agricultura desempeña un papel de vital importancia en Cuba, siendo uno de los pilares fundamentales de su economía y garantizando la seguridad alimentaria de la población. El país cuenta con una rica tradición agrícola que se remonta a siglos atrás, a pesar de los desafíos climáticos y económicos, ha logrado desarrollar sistemas de producción sostenibles. La ganadería juega un papel importante para complementar la producción agrícola y asegurar la seguridad alimentaria del país.

Es así como desde la década de los sesenta del pasado siglo comienza a ejecutarse un proyecto dirigido a potenciar la ganadería, con énfasis en la producción lechera. Con este fin se llevó a cabo un proceso inversionista que incluyó al sector industrial, la formación de capital humano como premisa para la asimilación de las nuevas tecnologías y una transformación genética hasta entonces sin precedentes. Esto permitió grandes progresos en la producción láctea e incrementó su consumo en la población[7].

1.3 La leche, beneficios e importancia:

La leche de vaca es básica para la alimentación en todas las etapas de la vida de la vida humana. Su procesamiento industrial ha permitido el acceso

generalizado a su consumo por parte de la población, contribuyendo a mejorar notablemente los niveles de salud. Desde el punto de vista de su composición, la leche es un alimento completo y equilibrado, que proporciona un elevado contenido de nutrientes en relación con su contenido calórico. Dentro de estos destacan el calcio y la vitamina D que, por su elevada presencia y su alta biodisponibilidad no igualada por ningún otro alimento, garantizan las ingestas diarias recomendadas. Estos dos micronutrientes están vinculados con el desarrollo y mantenimiento de procesos fisiológicos tales como: el crecimiento y mantenimiento óseo, la coagulación sanguínea, el metabolismo energético y neuromuscular, la función de enzimas digestivas, la división neuromuscular y la diferenciación celular. Su consumo debe considerarse necesario desde la infancia a la tercera edad[8].

Los beneficios de la leche de vaca no se limitan exclusivamente a su valor nutricional, sino que se extienden más allá. Constituyen un factor de prevención en determinadas patologías afluentes como son las enfermedades cardiovasculares, algunos tipos de cáncer, la hipertensión arterial o en patología ósea o dental. Puede contribuir también en la lucha frente al sobrepeso y la obesidad infantil[9].

1.4 Adulteración de la leche:

La adulteración de la leche es un problema que afecta a muchos países del mundo, incluyendo a Cuba. Este fenómeno implica agregar sustancias no permitidas o diluir la leche con agua u otros líquidos, con el objetivo de aumentar el volumen y obtener mayores ganancias económicas. Esta práctica fraudulenta compromete la calidad y la seguridad de la leche, ya que puede contener sustancias nocivas para la salud. Las adulteraciones cada día son más difíciles de detectar ya que las sustancias implicadas presentan una composición muy similar a las del producto de origen. Ahí la necesidad de contar con métodos más selectivos y específicos para poder detectar los adulterantes[10].

Uno de los mayores riesgos asociados con la adulteración de la leche es la introducción de sustancias nocivas para la salud. Una de las más utilizadas en

este proceso es el almidón, que tiene un alto índice glucémico. Un aumento de la cantidad de almidón en la dieta humana conduce a niveles elevados de glucosa en sangre, lo que representa una amenaza significativa para las personas que sufren de diabetes y otros trastornos del metabolismo[11].

Otro peligro está relacionado con la dilución de la leche con agua u otros líquidos. Esto no solo disminuye el valor nutricional de la leche, sino que también aumenta el riesgo de contaminación microbiológica. El agua utilizada en la adulteración puede contener bacterias, virus u otros patógenos que causan enfermedades transmitidas por alimentos.

1.5 Técnicas para detectar adulterantes:

Existen diversas técnicas para detectar adulterantes en la leche y garantizar la calidad y seguridad del producto. A continuación, se mencionan algunas de ellas:

- **Análisis físico-químico:** Es ampliamente utilizada en el análisis de la leche debido a su capacidad para medir características físicas y químicas claves. La determinación de parámetros como la densidad, acidez, contenido de grasa y proteínas ayuda a identificar posibles adulteraciones o diluciones. Los resultados obtenidos a través de este análisis proporcionan una evaluación objetiva de la calidad y autenticidad de la leche.
- **Análisis microbiológico:** Se centra en la detección de microorganismos patógenos o indicadores de contaminación en la leche. Permite evaluar la presencia de bacterias, hongos y otros microorganismos que pueden ser perjudiciales para la salud y pueden indicar un procesamiento inadecuado o contaminación en la cadena de producción de la leche.
- **Espectroscopia infrarroja cercana (NIR):** Se basa en la absorción de la luz infrarroja cercana por parte de los componentes de la leche. La composición química de la leche, como grasas, proteínas, lactosa y otros componentes, produce un patrón de absorción único. Al comparar los espectros obtenidos con los de la leche pura, es posible detectar

adulteraciones y diluciones, proporcionando una evaluación rápida y no destructiva de la calidad y autenticidad de la leche.

- **Cromatografía líquida de alta resolución (HPLC):** Se utiliza para separar y detectar los componentes individuales de la leche. Con la HPLC, es posible analizar la presencia de sustancias no permitidas, como aditivos, contaminantes o residuos de medicamentos. Permite una detección precisa y cuantificación de componentes específicos, garantizando la calidad y seguridad de la leche.
- **Pruebas de detección rápida:** Son métodos sencillos y rápidos que utilizan reactivos específicos para detectar adulterantes comunes en la leche. Los kits de prueba suelen incluir reacciones químicas o inmunológicas que indican la presencia de adulterantes como agua, almidón, melamina o urea. Estas pruebas ofrecen una evaluación rápida en el lugar, lo que facilita su uso tanto en laboratorios como en la industria alimentaria para un control rápido y preliminar de la calidad de la leche.

1.6 Espectroscopia

Como se refiere anteriormente la espectroscopia es uno de los posibles métodos de detección de adulterantes. Esta técnica se puede definir como el estudio de la interacción entre la materia y la radiación electromagnética en función de la longitud de onda o frecuencia de la radiación. En términos más simples, la espectroscopia es el estudio preciso del color generalizado de la luz visible a todas las bandas del espectro electromagnético (ver Figura 1). Al realizar esta disección y análisis de la luz de un objeto, el investigador puede inferir las propiedades físicas del mismo como: la temperatura, la masa, la luminosidad y la composición.




Figura 1: Espectro electromagnético.

Esta técnica se fundamenta en la Ley de Lambert-Beer (ecuación 1.1) que es una regla que define la relación entre las características y la cantidad de luz absorbida por una sustancia cuando le atraviesa un haz de luz (ver Figura 2). Se define matemáticamente como la relación entre la cantidad de luz absorbida y la concentración de soluto en la sustancia, la transmisión y la longitud de la muestra que atraviesa la luz [12].

$$\frac{I_1}{I_0} = 10^{-\alpha \cdot l} = 10^{-\varepsilon \cdot l \cdot c} = 10^{-A} \quad (1.1)$$

$$A = \varepsilon \cdot l \cdot c \quad (1.2)$$

Donde:

- A es la absorbancia, esto es la cantidad de luz absorbida.
- I_1 es la intensidad luminosa saliente.
- I_0 es la intensidad luminosa entrante.
- ε es la absortividad molar (o coeficiente de extinción), que se trata de una constante de proporcionalidad.
- l es la longitud atravesada por la luz en el medio.
- α es el coeficiente de absorción.
- c es la concentración de la sustancia que absorbe la luz.




Figura 2: Radiación absorbida por una muestra.

Para que el cumplimiento de la ley de Beer-Lambert sea válido, se deben tener en cuenta las siguientes condiciones:

- Homogeneidad del medio: Es importante que el medio absorbente, en este caso la leche, sea homogéneo en la región donde interactúa con la luz. La composición y las propiedades ópticas de la leche deben ser uniformes y sin variaciones significativas en la concentración de los componentes relevantes.
- Independencia de las sustancias absorbentes: Si hay más de una sustancia absorbente en la leche, es fundamental que actúen de manera independiente, es decir, que no haya interacciones entre ellas que afecten la absorción de la luz. Esto permite que se pueda atribuir la absorción observada a cada sustancia específica de manera precisa.
- Ausencia de dispersión en el medio absorbente: Es importante que el medio absorbente, en este caso la leche, no presente dispersión de la radiación. La luz incidente no debe ser dispersada ni reflejada significativamente por los componentes de la leche. En su lugar, la luz debe traspasar la sustancia o ser absorbida por ella. La falta de dispersión asegura mediciones más precisas de la absorbancia de la leche en las diferentes longitudes de onda y ayuda a identificar los adulterantes con mayor exactitud.
- Rayos paralelos: Para obtener resultados precisos, es necesario que la luz incidente esté formada por rayos paralelos. Esto garantiza que cada

rayo atravesase la misma longitud de la leche, lo cual es crucial para calcular correctamente la absorbancia de la muestra.

- Medición independiente de cada longitud de onda: Al medir de manera individual cada longitud de onda, se obtiene información detallada sobre la absorbancia de la leche en diferentes rangos espectrales. Esto es crucial para identificar y caracterizar los componentes específicos presentes en la muestra de leche y detectar posibles adulterantes con mayor precisión.
- La luz incidente no debe ser invasiva: La luz incidente no debe tener un efecto intrusivo en los átomos o moléculas del medio absorbente. No debe provocar reacciones químicas ni alterar las propiedades ópticas de la leche. La interacción entre la luz y la muestra debe ser puramente absorbente, sin introducir cambios significativos en el sistema.

1.6.1 Espectroscopía ultravioleta-visible (UV-VIS):

La espectroscopia ultravioleta-visible es un tipo de espectroscopia de absorción en la que se ilumina una muestra con rayos electromagnéticos de varias longitudes de onda en el rango ultravioleta (UV) y visible (VIS) (ver Figura 3). Según la sustancia, la muestra absorbe parcialmente los rayos de luz ultravioleta o visible. El resto, es decir, la luz transmitida, se registra como una función de la longitud de onda mediante un detector adecuado. Este produce entonces el espectro UV-VIS único de la muestra (también conocido como el “espectro de absorción”)[13].




Figura 3: Espectro electromagnético ultravioleta-visible (UV-VIS).

La espectroscopia ultravioleta-visible (UV-VIS) es una potente técnica para diversas aplicaciones de distintas industrias y segmentos de mercado. Cuando una sustancia absorbe el máximo de luz a una determinada longitud de onda, se da una relación única entre la sustancia y su espectro UV-VIS. Esta relación puede servir para:

- **Análisis cualitativos:** Determinar la presencia de ciertas sustancias. Por ejemplo, la determinación del contenido de caroteno en aceites y grasas comestibles, la identificación de contaminación, como el cromo y el hierro en el agua, la identificación de la cianocobalamina y la comprobación de la pureza del ADN/ARN.
- **Análisis cuantitativos:** Determinar las cantidades de ciertas sustancias. Por ejemplo, la determinación de la concentración de sustancias en el agua, como el amoníaco, la determinación de la unidad de amargor de las bebidas alcohólicas, la medición del contenido de azúcar en las bebidas y la cuantificación de las proteínas.

1.6.2 Espectroscopía infrarroja cercana (NIR):

En específico la región del infrarrojo en el espectro electromagnético comprende la zona entre el rango visible y las microondas y se divide en tres regiones: cercano, medio y lejano, en función de la longitud de onda. En el caso de la espectrometría NIR (infrarrojo cercano), la longitud de onda oscila entre 780 y 2.500 nanómetros (nm) (Ver Figura 4).




Figura 4: Rango de longitud de onda que ocupa la espectroscopia NIR en el espectro electromagnético.

La espectrometría NIR se basa en la aplicación de radiación infrarroja sobre una muestra dispuesta a ser analizada, según la naturaleza de los enlaces de las moléculas que la componen absorberá una cierta cantidad de energía. La representación gráfica de los valores de energía absorbida (absorbancia) por la muestra en las diferentes longitudes de onda de NIR dará lugar al espectro. De esta manera se pueden identificar ciertos atributos en las muestras como: grasa, humedad y acidez. Luego con esta información espectral de interés se pueden identificar los atributos en muestras desconocidas[14].

1.7 Análisis del estado del arte referente a temática:

Para conocer el estado de la temática tratada en el presente trabajo, se realizó una búsqueda bibliografía internacional, regional (América Latina) y nacional con el fin de realizar un análisis de las soluciones implementadas.

En [3] se realiza el diseño y desarrollo de un sistema de sensor espectroscópico no destructivo, multiespectral, portátil, de bajo costo y basado en algoritmos de inteligencia artificial (IA) que se puede emplear para detectar el adulterante de la leche en tiempo real. El sistema de sensores diseñado utiliza el método espectroscópico con rangos de longitud de onda de (410-940 nm) que consta de tres bandas diferentes de espectro ultravioleta (UV), visible e infrarrojo (IR) para mejorar la precisión de la detección. El sistema está conectado a Internet y muestra los resultados de los adulterantes detectados en una página web diseñada para este propósito. En este artículo el problema de detección de adulterantes se formula como un problema de clasificación. Este se resuelve mediante algoritmos de aprendizaje automático, se utilizaron árboles de decisión, Naive Bayes, análisis discriminante lineal, máquinas de vectores de soporte (SVM support vector machine por sus siglas en inglés) y modelos de redes neuronales. El modelo está entrenado para cinco clases diferentes con cuatro adulterantes, salicilato de sodio, dextrosa, peróxido de hidrógeno, sulfato de amonio y leche pura.

El prototipo del sistema de sensor habilitado para IA (Ver Figura 5) consta del sistema espectroscópico Triad SparkFun, una placa de desarrollo Arduino, cable Qwiic, módulo inalámbrico (ESP8266). La PC se usa para el registro de

los datos y la implementación de los módulos de software de IA de redes neuronales. Los datos del sensor espectral se comunicarán en serie a la placa Arduino y se transmiten a una computadora personal a través de un módulo Wi-Fi. El módulo Wi-Fi permite al usuario comunicar los datos espectrales recopilados a la PC.

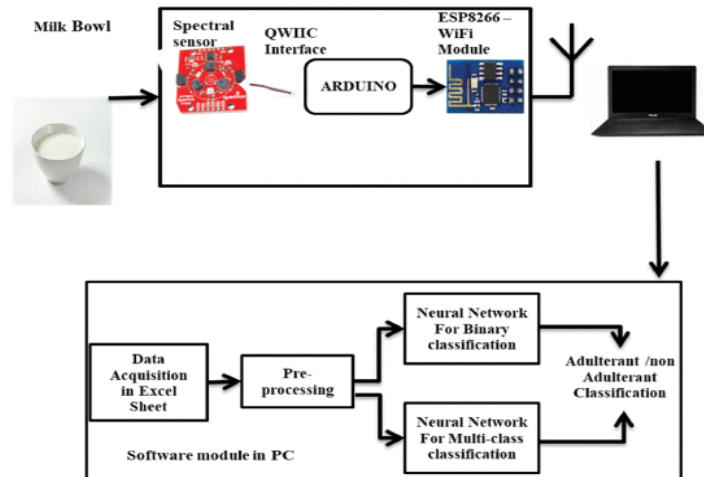


Figura 5: El sistema de sensor multiespectral habilitado por IA.

Una vez que se completan las conexiones de configuración experimental, los datos espectrales se recopilan ejecutando el programa de adquisición.

El sistema propuesto es capaz de detectar cuatro adulterantes diferentes con un 100% de precisión mientras que, en su mayoría, otros métodos pueden detectar uno. El sistema desarrollado es portátil, rápido, no destructivo y menos costoso en comparación con otros. Tiene la desventaja de utilizar una PC como unidad de procesamiento de los datos y esto encarece el costo del sistema.

El proyecto [15] tiene como objetivo desarrollar una matriz de sensores multiespectrales de lectura rápida y bajo costo para predecir el nivel de nitrógeno (N) en las hojas de forma no invasiva. El módulo sensor propuesto se ha desarrollado utilizando dos sensores multiespectrales basados en reflectancia (visible e infrarrojo cercano (NIR)). Puede capturar los datos de reflectancia en 12 longitudes de onda diferentes (seis para cada sensor). Se realiza el experimento en hojas de canola en un ambiente de invernadero controlado, así como en el campo. En el experimento de invernadero, se

recolectaron datos espectrales de 87 hojas de 24 plantas de canola, sujetas a niveles variables de fertilización con N. Posteriormente, 42 cultivares de canola fueron sometidos a niveles altos y bajos de nitrógeno en el experimento de campo. Se empleó el algoritmo de k vecinos más cercanos (KNN por sus siglas en inglés) para modelar los datos de reflectancia. El modelo entrenado muestra una precisión promedio del 88,4 % en el conjunto de prueba para el experimento de invernadero y del 79,2 % para el experimento de campo.

Después de recopilar los datos, el modelado y el procesamiento se realiza en una computadora utilizando MATLAB 2018b, Esta una desventaja del sistema desarrollado, ya que el uso de una PC como unidad de procesamiento encarece el costo del proyecto y puede dificultar su ejecución.




Figura 6: Sistema diseñado para la lectura de nitrógeno en las hojas.

El objetivo principal en [16] es calibrar y probar (precisión y rendimiento) el espectrómetro de mano AS7265X. Con el fin de mejorar la clasificación de imágenes de teledetección y evaluar la precisión de este comparándolo con una biblioteca espectral definida. Los resultados muestran una buena capacidad de discriminación para el espectrómetro de mano AS7265X para la vegetación de hojas en el campo. Además, se verificó la confiabilidad del sensor.

Los datos de la muestra se adquirieron en condiciones de luz natural (Ver Figura 7). El análisis de los espectros de la parcela de vegetación se realizó para determinar la diferencia entre los espectros de las hojas debido al estado de las mismas (sanas y no sanas). El uso de una PC en el diseño del sistema encarece el costo del proyecto y dificulta su ejecución.



Figura 7: Adquisición de los datos.

En la investigación [17] se estudia la técnica de espectroscopia THz que tiene la capacidad de penetración y es un método no invasivo, por lo que tiene potencial para desarrollar modelos de predicción de adulterantes en alimentos. Esta tecnología basada en la aplicación de láser pulsado a altas frecuencias se presenta como una alternativa a los rayos X para el proceso de verificación de los alimentos para compuestos nocivos, toxinas y microorganismos. Se colectaron cincuenta y dos artículos, seleccionando cuarenta y cinco por ser estudios primarios. En la mayoría de estos artículos las muestras trabajadas fueron diferentes productos alimenticios como carne, chocolate, aceite, productos agrícolas, fruta y matrices alimentarias mixtas. Se concluye que el uso del método THz es una solución tecnológica eficiente y rápida para la industria alimentaria.

Las imágenes THz se obtienen mediante transmisión o reflexión de las ondas THz, entre sus ventajas se tienen:

- “Las imágenes THz proporcionan información espectral de la gama de frecuencias de THz e imágenes de distribución de densidad espacial de las muestras
- Las imágenes tienen una resolución espacial superior y pueden utilizarse para la identificación de materiales y el análisis de componentes.
- El THz puede utilizarse para el examen no destructivo de muestras.

En el trabajo de investigación [18] se modeló un sensor óptico basado en una película delgada nanométrica de oro utilizando el software Matlab 2020. Con este se simuló la reflectancia de un haz de luz en función del ángulo incidente en presencia de leche pura y leche con distintos porcentajes de dilución en agua. Mediante el sensor óptico que propone este trabajo, se busca obtener corrimientos en los espectros de reflectancia cuando la leche cambia su índice de refracción por adición de agua. Dependiendo del corrimiento podemos determinar el porcentaje de agua añadida. El sensor consiste en una película delgada de espesor nanométrico depositada sobre un prisma de vidrio (configuración kretschmann). Sobre una de las caras del prisma se deposita una película delgada metálica cuyo metal a utilizar es el oro, con un espesor que puede variar de 10 a 100 nanómetros (nm). La luz que el láser emite tiene una longitud de onda de 633 nm que corresponde al color rojo. El láser primero pasa a través del prisma, luego incide sobre la película delgada y esta va a funcionar como un espejo reflejando la luz del láser incidente. Al otro lado de la película estaría el material a censar, en este caso la leche, que es el objeto de estudio.

Conjuntamente se realizó un estudio de la determinación del espesor óptimo del sensor para obtener la máxima sensibilidad, el espesor óptimo de la película delgada para aumentar la sensibilidad es de 90 nm. Es importante señalar que el software Matlab requiere un ordenador para su ejecución y esto encarece el costo del sistema.

En el estudio [19] se describe el método de determinación del peróxido de hidrógeno en la leche mediante cromatografía líquida de alta resolución. La evaluación cuantitativa indirecta del peróxido de hidrógeno se lleva a cabo de

acuerdo con la cantidad de óxido de trifenilo producido después de la reacción entre el peróxido de hidrógeno con trifenilfosfano. Se demostró que la interacción de trifenilfosfano y peróxido de hidrógeno requiere unos 40 min. El límite de detección de este método es de 0,28 mg/L. La recuperación de peróxido de hidrógeno fue del 97,8% al 103,8%.

A pesar de que la leche consiste en muchas sustancias, no contiene oxidantes fuertes susceptibles de reaccionar con trifenilfosfano. El método propuesto podría considerarse adecuado para su uso en la mayoría de los laboratorios (técnica de rutina) y lo suficientemente sensible como para determinar el peróxido de hidrógeno al nivel de los estándares permitidos en diferentes países.

El método de detección de adulterantes en la leche propuesto en este estudio tiene la desventaja de que el proceso de detección se realiza en laboratorios, es un método destructivo y no se puede obtener una respuesta en tiempo real. Se limita solamente a la detección de una sola sustancia el peróxido de hidrógeno.

1.7.1 Tabla comparativa de la bibliografía estudiada

Tabla 1: Comparación de la bibliografía estudiada.

Artículo	Técnica de Predicción	Hardware	Sensor que se utilizó	Sustancia analizada	Calidad de los resultados
[3]	Espectroscopia	Arduino Uno, ESP8266, Laptop (para visualización de los resultados)	AS7265X	Leche (cuatro adulterantes diferentes a identificar: silicato de sodio, dextrosa, peróxido de hidrógeno, sulfato de amonio)	Alta El algoritmo se formuló para el ajuste de hiperparámetros lo que mejoró la precisión de 92,7% al 100%
[15]	Espectroscopia (visible y NIR)	Raspberry Pi para conectar y controlar los sensores Multiplexor (mux)		Hojas de planta con el fin de medir los niveles de nitrógeno	Medio
		PC para el procesamiento de los datos utilizando MATLAB 2018b			El resultado concluye que el sistema de detección propuesto puede ser viable para determinar el estado del nitrógeno de las hojas. El modelo entrenado muestra una precisión promedio de 88.4% en el conjunto de prueba para el experimento de invernadero y 79.2% para el experimento de campo.
[16]	Espectroscopia	Ordenador para visualizar y procesar los datos adquiridos en las mediciones	AS7265X	Hojas de plantas Para registrar y comparar su firma espectral y determinar si están sanas o no	Buena Los resultados muestran una buena capacidad de discriminación del espectrómetro de mano AS7265X para la vegetación de hojas en el campo
[17]	Espectroscopia THz			carne, chocolate, aceite, productos agrícolas, fruta y matrices alimentarias mixtas	Buena El estudio concluye que la espectroscopia THz es una tecnología eficiente, rápida y no destructiva.



[18]	Espectroscopia	PC	Sensor óptico basado en una película delgada de oro depositada sobre un prisma de vidrio (simulado en el software Matlab 2020)	Leche (adulterada con distintas concentraciones de agua)	Medio Se concluye que el método es eficaz sobre todo cuando los porcentajes de dilución en agua son pequeños
[19]	Cromatografía líquida			Leche (con el fin de detectar niveles de peróxido de hidrógeno)	Medio El método propuesto es lo suficientemente sensible como para determinar el peróxido de hidrógeno al nivel de los estándares permitidos en diferentes países

1.8 Equipos comerciales utilizados en la detección de adulterantes

Como se muestra a continuación los equipos comerciales para la detección de adulterantes en la leche son muy costosos. Esto dificulta su utilización en países subdesarrollados y pequeños productores.

Tabla 2: Comparación de equipos comerciales para la detección de adulterantes en la leche.

Nombre	Adulterante detectado	Precio en USD	Foto
Ultrasonic Milk Analyzer Ekomilk Bond Total[20]	Proporciona resultados de prueba rápidos para: grasa, proteína, sólidos no grasos, lactosa, densidad, punto de congelación, agua añadida, pH, temperatura y conductividad en leche fresca (vaca, oveja y cabra)	\$3,620.00	
Ekomilk Ultra 40S Ultrasonic Milk Analyzer[21]	Recuento de células somáticas, contenido de grasa, contenido de proteínas, sólidos totales, densidad, agua añadida, punto de congelación, lactosa, pH, temperatura, conductividad y residuos antibióticos	\$2,440.00	

Lactoscan Milk analyzers[22]	Proteína, lactosa, solidos, agua añadida, punto de congelación y grasa.	\$1,242.20	
Julie X High accurate and is fully automatic Dairy Milk Analyzer[23]	Proteína, lactosa, solidos, agua añadida, punto de congelación y grasa.	\$6,300.00 - \$10,080.00	

1.9 Conclusiones del capítulo

A partir del estudio realizado en el capítulo se concluye que la espectroscopia es una técnica altamente favorable para la construcción de un detector de adulterantes de bajo costo en la leche. Esto se debe a que es una técnica no destructiva y no invasiva, lo que implica que las muestras no requieren de preparación adicional ni se ven alteradas físicamente durante el análisis. Esta característica resulta especialmente beneficiosa en términos de reducción de costos asociados con el manejo y procesamiento de las muestras, al no requerir el uso de reactivos adicionales. Esta técnica tiene la capacidad de distinguir y cuantificar diferentes componentes y compuestos en una muestra, basándose en sus firmas espectrales únicas. Como resultado, se puede lograr una detección precisa y selectiva de adulterantes específicos en la leche, incluso en concentraciones bajas.

Un aspecto relevante es la rapidez en el análisis y la obtención de resultados inmediatos que ofrece la espectroscopia. Esto es particularmente importante en la detección de adulterantes en la leche, donde se requiere una respuesta rápida para garantizar la seguridad alimentaria. La espectroscopia permite

realizar análisis en tiempo real, lo que agiliza la toma de decisiones y la implementación de medidas correctivas si se detectan adulterantes en la leche.

A partir del análisis de la bibliografía estudiada se puede observar que el sensor AS7265X funciona correctamente en la detección de adulterantes y es una excelente opción. Por otro parte, los proyectos que requieren el procesamiento de datos utilizan una PC lo que encarece el proyecto y dificulta su ejecución.

La mayoría de los equipos comerciales para la detección de adulterantes son extremadamente costosos debido al tipo de tecnología que emplean y su demanda en el mercado. Esto dificulta su acceso en países subdesarrollados y pequeños productores.

Finalmente, la realización de un detector de adulterantes en la leche de bajo costo permitiría una detección temprana y eficiente de dichas sustancias, asegurando la calidad y seguridad de los productos lácteos consumidos por la población.

CAPÍTULO II – “MATERIALES Y MÉTODOS”

2.1 Hardware empleado

Los dispositivos de detección de adulterantes son herramientas fundamentales en diversos ámbitos como: la industria alimentaria, el control de drogas y el monitoreo ambiental. Estos dispositivos se utilizan para identificar sustancias no deseadas o contaminantes en muestras, lo que contribuye a garantizar la seguridad y la calidad de los productos.

Uno de los principales desafíos asociados con estos dispositivos es su elevado costo. Los equipos de detección convencionales suelen requerir tecnologías sofisticadas, componentes especializados y un alto nivel de precisión, lo que se traduce en un precio elevado. Esto puede limitar su accesibilidad y uso generalizado, especialmente en entornos donde los recursos financieros son limitados.

2.1.1 Microordenadores “Computadoras de placa única”

Una posible solución al problema del elevado precio es el empleo de microordenadores de placa única, que son dispositivos compactos y de bajo costo. Son altamente versátiles y pueden ser programados y personalizados para satisfacer las necesidades específicas de detección de adulterantes. Se pueden utilizar en combinación con sensores y actuadores especializados para crear sistemas de detección portátiles y de bajo costo. La comunidad de desarrolladores en torno a estos microordenadores ha crecido considerablemente, lo que significa que existe una amplia gama de recursos y conocimientos disponibles para apoyar su implementación.

Al emplear microordenadores de placa única en la detección de adulterantes, se puede reducir significativamente el costo de los equipos, lo que los hace más accesibles para una variedad de aplicaciones y entornos. Esto puede ser especialmente beneficioso en países en desarrollo, pequeñas empresas o laboratorios con presupuestos limitados, donde la adquisición de equipos costosos puede ser un obstáculo.

Estos dispositivos también presentan algunos inconvenientes, como la imposibilidad de realizar una ampliación en el hardware, la difícil reparación en el caso de tener averías y la dificultad en el uso para algunos usuarios al contar la mayoría con sistemas operativos basados en Linux[24]. En la Figura 8 se muestran imágenes de algunas SBC.



Raspberry Pi 3B



The Odroid N2



LattePanda 3 Delta 864

Figura 8: Ejemplos de placas SBC.

2.1.2 Raspberry Pi 3b

Uno de los dispositivos más utilizados dentro del área de los computadores de placa única es la Raspberry Pi 3B (ver Figura 9). Esta pequeña placa de computadora de bajo costo ofrece una amplia gama de ventajas que la hacen muy adecuada para este propósito.

En primer lugar, cuenta con un potente procesador de cuatro núcleos y 1.2 GHz, lo que le permite realizar tareas computacionales de manera eficiente. Esto es fundamental para el procesamiento y análisis de datos necesarios en la detección de adulterantes. La capacidad de procesamiento de la Raspberry Pi 3B garantiza un rendimiento óptimo al ejecutar algoritmos de detección complejos en tiempo real. Viene con una amplia variedad de puertos de E/S, incluyendo puertos USB, HDMI, Ethernet y GPIO (General Purpose Input/Output). Estos puertos permiten la conexión de diferentes sensores, actuadores y otros componentes necesarios para la implementación del detector de adulterantes. La versatilidad de la Raspberry Pi 3B hace que sea fácil de integrar con una amplia gama de dispositivos y periféricos externos.

Otra característica destacada es que cuenta con Wi-Fi integrado y soporte para Bluetooth, lo que facilita la transferencia de datos y la comunicación con otros dispositivos. Esto puede ser especialmente útil en aplicaciones de detección de adulterantes, donde la conectividad inalámbrica puede ser necesaria para la transmisión de datos en tiempo real o para la interacción con sistemas externos[25].

Tiene un amplio soporte de software y una comunidad de desarrolladores activa. Existen numerosos sistemas operativos y entornos de desarrollo disponibles, como Raspbian (basado en Linux), que brindan herramientas y recursos para programar y personalizar la funcionalidad del dispositivo según las necesidades específicas de detección de adulterantes. La comunidad de usuarios y desarrolladores ofrece foros, tutoriales y proyectos compartidos que pueden servir como referencia y apoyo en la implementación del detector.




Figura 9: Raspberry Pi 3 Modelo B y sus elementos fundamentales.

Tabla 3: Especificaciones de la Raspberry Pi 3b [26].

Procesador	Broadcom BCM2837, Cortex-A53 (ARMv8) 64-bit SoC
Frecuencia de reloj	1,2 GHz
GPU	VideoCore IV 400 MHz
Memoria	1GB LPDDR2 SDRAM
Conectividad inalámbrica	2.4GHz IEEE 802.11.b/g/n Bluetooth 4.
Conectividad de red	Fast Ethernet 10/100 Gbps
Puertos	GPIO 40 pines HDMI 4 x USB 2.0 CSI (cámara Raspberry Pi) DSI (pantalla táctil) Toma de auriculares / video compuesto Micro SD Micro USB (alimentación)
Fecha de lanzamiento	29/2/2016

2.1.3 Sensores espectroscópicos

Cuando se considera el panorama de los sensores espectroscópicos, existen múltiples opciones disponibles en el mercado. A continuación, se presentan alguna de ellas:

- **Sensor AS7265x:** Es fabricado por ams AG, ofrece una amplia gama de aplicaciones en el análisis espectral. Su rango de longitud de onda cubre aproximadamente desde 410 nm (visible) hasta 940 nm (infrarrojo cercano). En términos de precio, el sensor AS7265x suele tener un costo que varía entre los 50 y 150 dólares estadounidenses, dependiendo del proveedor y las características adicionales que pueda ofrecer.
- **Sensor Hamamatsu S11639:** Este sensor de alta calidad y resolución espectral está diseñado para aplicaciones científicas y de investigación que requieren un análisis detallado del espectro. Si bien los rangos de longitud de onda específicos pueden variar según el modelo exacto, en general se puede esperar que cubra el rango 200 nm hasta 1000 nm. En términos de precio, el sensor Hamamatsu S11639 suele tener un costo más elevado debido a sus características avanzadas y precisión, estimándose en un rango de precios entre los 200 y 500 dólares estadounidenses, o incluso más, dependiendo del modelo y las especificaciones precisas.

El sensor AS7265x destaca como la mejor opción debido a las siguientes razones. En primer lugar, ofrece un amplio rango de longitud de onda que abarca desde aproximadamente 410 nm hasta 940 nm, lo que permite realizar mediciones precisas en el espectro visible e infrarrojo cercano. Esta versatilidad es especialmente útil en aplicaciones que requieren un análisis detallado y completo de la luz.

En segundo lugar, la relación calidad-costos es muy buena, debido a su buena resolución espectral y su capacidad para proporcionar mediciones precisas y simultáneas en 18 canales espectrales diferentes. Esto permite un análisis más detallado y una mejor caracterización de la luz y sus componentes. Ofrece una integración sencilla y es compatible con una

variedad de plataformas y microcontroladores, lo que facilita su implementación en diferentes sistemas y aplicaciones.

2.1.4 Sensor AS7265x

Descripción:

La familia AS7265x (Ver Figura 10) incorpora tres chips para ofrecer un conjunto de sensores multispectrales de 18 canales que cubren las longitudes de ondas de 410nm a 940nm. El AS72651 cubre las longitudes de onda NIR de 600nm a 870nm y sirve como controlador maestro del conjunto. Cuando se combina con el AS72652 (respuesta espectral de 560nm a 940nm) y el AS72653 (respuesta espectral de 410nm a 535nm) el conjunto entero entrega 18 canales con filtro gaussiano con un ancho de banda de media anchura (FWHM) de 20nm.

El funcionamiento del conjunto de chips AS7265x requiere del uso de un firmware que debe cargarse en una memoria flash a través de una interfaz UART. Los sensores AS72651, AS72652 Y AS72653 están precalibrados con una fuente de luz específica.

Cada dispositivo tiene dos controladores LED integrados con corriente programable y puede ser temporizado para aplicaciones de obturación electrónica. La familia de dispositivos integra filtros gaussianos que también proporcionan aperturas incorporadas para controlar la luz que entra en el conjunto de sensores[27].



Figura 10: Sensor de espectroscopía SparkFun Triad - AS7265x.

Principio de funcionamiento:

Cada dispositivo contiene un convertidor analógico-digital (ADC con resolución de 16 bits) que integra la corriente del fotodiodo de cada canal. Al finalizar el ciclo de conversión, el resultado se transfiere a los registros de datos correspondientes. Las transferencias son de doble buffer para asegurar la integridad de datos.

Principales ventajas:

- Solución compacta de chips de espectrometría de 18 canales.
- No se requiere un acondicionamiento adicional de la señal.
- Paquete pequeño y robusto con apertura incorporada.

Características Principales:

- Juego de 3 chips que incluye un dispositivo maestro que proporciona 18 canales visibles y NIR de 410nm a 940nm, cada uno con 20nm FWHM.
- Interfaz UART o I²C.
- Conjunto de filtros visibles realizados con filtros de interferencia de silicios.
- ADC de 16 bits con acceso digital.
- Controladores LED programables.

2.2 Software empleado

2.2.1 Python

Para implementar la solución propuesta se empleó el lenguaje Python, el cual es un lenguaje de programación muy popular y utilizado en la comunidad de desarrolladores que utilizan la Raspberry Pi. Python es un lenguaje de propósito general, lo que significa que se puede utilizar para crear una variedad de programas diferentes y no está especializado en ningún problema específico. Esta versatilidad, junto con su facilidad para los principiantes, lo ha convertido en uno de los lenguajes de programación más utilizados en la actualidad[28]. La claridad y simplicidad del código Python también contribuyen a la facilidad de mantenimiento y depuración del sistema.

Python cuenta con una amplia colección de bibliotecas y módulos de software que facilitan el procesamiento de datos y la implementación de algoritmos de detección. Bibliotecas populares como NumPy y Pandas proporcionan herramientas para el análisis de datos y el manejo de matrices. También existen bibliotecas especializadas en aprendizaje automático y visión por computadora, como Scikit-learn y OpenCV, que pueden ser utilizadas para mejorar la precisión y la eficacia del detector.

En cuanto a la compatibilidad con la Raspberry Pi, como se comentó anteriormente. Python es uno de los lenguajes de programación más utilizados en este entorno. Python se distribuye de forma predeterminada en las distribuciones de Linux, como Raspbian, que es el sistema operativo recomendado para la Raspberry Pi.

2.2.2 Flask

En la actualidad existen muchas opciones para crear páginas web y muchos lenguajes (PHP, JAVA), en este caso Flask nos permite crear de una manera muy sencilla aplicaciones web con Python. Flask es un “micro” Framework escrito en Python y concebido para facilitar el desarrollo de Aplicaciones Web bajo el patrón MVC.

Al instalar Flask tenemos las herramientas necesarias para crear una aplicación web funcional. De ser necesaria una nueva funcionalidad hay un conjunto muy grande extensiones (plugins) que se pueden instalar con Flask para darle distinta funcionalidad. Con solo instalarlo no se tienen todas las funcionalidades que se pueden necesitar, pero de una manera muy sencilla se pueden extender el proyecto con nuevas funcionalidades por medio de plugins[29].

Ventajas de usar Flask:

- Flask es un “micro” Framework: Para desarrollar una App básica o que se quiera desarrollar de una forma ágil y rápida Flask puede ser muy conveniente, para determinadas aplicaciones no se necesitan muchas extensiones y es suficiente.
- Incluye un servidor web de desarrollo: No se necesita una infraestructura con un servidor web para probar las aplicaciones sino de una manera sencilla se puede correr un servidor web para ir viendo los resultados que se van obteniendo.
- Tiene un depurador y soporte integrado para pruebas unitarias: Si tenemos algún error en el código que se está construyendo se puede depurar y ver los valores de las variables. Además, está la posibilidad de integrar pruebas unitarias.
- Buen manejo de rutas: Cuando se trabaja con Apps Web hechas en Python se tiene el controlador que recibe todas las peticiones que hacen los clientes y se tienen que determinar que ruta está accediendo el cliente para ejecutar el código necesario.
- Flask es Open Source y está amparado bajo una licencia BSD.
- Buena documentación, código de GitHub y lista de correos.
- Routing: Flask permite definir las rutas URL de la aplicación y asociar funciones de vista a cada ruta. Esto permite que la aplicación responda a las solicitudes del cliente y devuelva las respuestas correspondientes.
- Renderizado de plantillas: Flask utiliza el motor de plantillas Jinja2 para generar contenido HTML dinámicamente. Las plantillas permiten combinar HTML estático con variables y lógica de programación, lo que facilita la creación de páginas web dinámicas y personalizadas.
- Integración con bases de datos: Flask es compatible con una variedad de bases de datos, incluyendo SQL y NoSQL. Puede integrarse fácilmente con bibliotecas de bases de datos como SQLAlchemy para realizar operaciones de lectura y escritura en la base de datos.
- Manejo de formularios: Flask proporciona funcionalidades para trabajar con formularios HTML. Puede manejar la validación de datos enviados

desde formularios, procesar la información y realizar acciones basadas en ella.

- Extensibilidad: Flask es altamente extensible y permite a los desarrolladores agregar funcionalidades adicionales utilizando extensiones y complementos. Existen numerosas extensiones disponibles para tareas comunes como autenticación de usuarios, manejo de sesiones, generación de gráficos, integración de API, entre otros.
- Integración con otras bibliotecas y frameworks: Flask puede integrarse fácilmente con otras bibliotecas y frameworks de Python. Por ejemplo, puede combinarse con bibliotecas de visualización de datos como Matplotlib o con frameworks de aprendizaje automático como TensorFlow

2.3 Métodos de detección multivariable

Los métodos de detección multivariable son técnicas analíticas utilizadas para identificar anomalías o patrones inusuales en conjuntos de datos complejos que involucran múltiples variables. El enfoque multivariable considera las relaciones y las interacciones entre las variables en el conjunto de datos en lugar de analizar cada una de forma independiente. Esto permite capturar la complejidad y las interdependencias entre las variables para revelar información oculta o detectar patrones sutiles que no serían evidentes mediante métodos univariante.

Son una buena opción para abordar problemas de fraude alimentario que no se pueden resolver con una sola variable, ya sea porque la respuesta requerida es de naturaleza compleja o porque ninguna señal única actúa como un marcador inequívoco. Para la autenticación de alimentos, son una de las opciones más comúnmente utilizadas y para la adulteración de alimentos se recomiendan cuando no se conoce el adulterante[30].

En las mediciones realizadas por el detector de adulterantes diseñado en este trabajo se generan un gran número de datos con múltiples variables. Por lo que se hace necesario la utilización de un método con capacidad de discriminación

mejorada, reducción de interferencias y ruido, así como el análisis en tiempo real y la toma de decisiones inmediatas.

En muchos casos las observaciones multivariantes no pueden ser detectadas como los valores extremos cuando cada variable se considera de forma independiente. La detección de valores atípicos (referidos en la literatura como outliers) sólo es posible cuando se realiza un análisis multivariante y las interacciones entre las diferentes variables se comparan dentro de la clase de datos[31].

Existen diferentes métodos de detección multivariable, y cada uno de ellos se basa en suposiciones y enfoques particulares. Algunos de los métodos más comunes incluyen:

- **Análisis de componentes principales (PCA):** PCA es una técnica que reduce la dimensionalidad de los datos multivariados al transformar las variables originales en un conjunto de componentes principales. Al analizar la varianza de los componentes principales, se pueden identificar valores atípicos o anomalías que se desvían significativamente del comportamiento esperado.
- **Análisis de discriminante lineal (LDA):** LDA es una técnica que se utiliza para encontrar una combinación lineal de variables que mejor discrimine entre diferentes grupos o clases. Al proyectar los datos en este espacio discriminante, es posible detectar observaciones que se desvían de las expectativas establecidas por los grupos de datos.
- **Análisis de valores atípicos robustos (ROB):** este enfoque se basa en la detección de valores atípicos utilizando medidas robustas de dispersión y distancia en lugar de suponer distribuciones específicas. Los métodos ROB son menos sensibles a valores extremos y pueden proporcionar detección más confiable en presencia de datos contaminados o ruidosos.
- **Análisis de regresión multivariante (MRA):** MRA se utiliza para evaluar la relación entre múltiples variables predictoras y una variable de

respuesta. Al identificar valores residuales inusuales o inesperados, es posible detectar casos anómalos o atípicos en los datos.

2.3.1 Análisis de Componentes Principales (PCA)

El análisis de componentes principales (PCA) es uno de los primeros métodos empleados en análisis de datos, procesamiento de matrices y aprendizaje automático[32]. Esta técnica se basa en un concepto fundamental del álgebra lineal: cualquier vector puede expresarse como una combinación lineal de vectores base[33]. PCA ofrece una perspectiva única para comprender y explorar conjuntos de datos complejos, permitiendo la reducción de dimensionalidad, la compresión de datos, la extracción de características y la visualización de datos.

Los espectros NIR de esta investigación se adquieren en 18 puntos de longitud de onda, lo que constituye un conjunto muy redundante. Los espectros NIR son bastante pobres en información, es decir, nunca contienen características nítidas, como picos de absorción, como puede ser el caso de la espectroscopia Raman o MIR. Por esta razón, la mayoría de las características de los espectros NIR en diferentes longitudes de onda están altamente correlacionadas. Por lo que resulta ideal aplicar PCA para eliminar los componentes correlacionados en los datos, proyectando el conjunto de datos multidimensionales (18 dimensiones para este conjunto de datos) a un espacio de dimensionalidad mucho más bajo [34].

Uno de los beneficios clave de PCA es su capacidad para volver a expresar un conjunto de datos en una nueva base compuesta por los componentes principales. Estos componentes se calculan de tal manera que capturan la máxima variabilidad presente en los datos originales y los proyecta en un nuevo subespacio con dimensiones iguales o menores (ver Gráfico 1)[35]. Al eliminar el ruido y resaltar las estructuras ocultas, PCA revela patrones y relaciones subyacentes que podrían haber pasado desapercibidos en el espacio de datos original. Esta capacidad de PCA es especialmente valiosa en problemas donde la dimensionalidad de los datos es alta y se busca simplificar su análisis[36].




Gráfico 1: Las dimensiones de la varianza máxima (PCA1 y PCA2) como resultado de PCA.

Al reducir la dimensionalidad del conjunto de datos mediante la selección de un número menor de componentes principales, es posible representarlos de manera más compacta. Comprimir los datos es particularmente beneficioso en situaciones donde los conjuntos son grandes y complejos, ya que reduce el espacio de almacenamiento y acelera los algoritmos de análisis. También puede ser útil en la transmisión y el intercambio eficiente, minimizando la carga computacional requerida para esto. La extracción de características mediante PCA proporciona un enfoque sistemático para identificar y utilizar las dimensiones más informativas de los datos[37].

Además de sus aplicaciones en reducción de dimensionalidad y extracción de características, PCA también se utiliza para la visualización de datos. Al proyectar los datos en un espacio de menor dimensión, como un plano o un espacio tridimensional, es posible representar y explorar visualmente las relaciones entre las observaciones. Esto facilita su comprensión e interpretación, así como la detección de patrones o anomalías visuales.

2.3.2 Análisis Discriminante Lineal (LDA)

El análisis discriminante lineal (LDA) es una técnica estadística de transformación lineal que se utiliza para la reducción de la dimensionalidad. Sin embargo, a diferencia de PCA, LDA es un método de aprendizaje supervisado, lo que significa que tiene en cuenta las etiquetas de clases. LDA tiene como objetivo maximizar la separación entre las diferentes clases y minimizar la

variación de los datos dentro de las mismas[38]. A continuación, se presenta un ejemplo para facilitar su comprensión.

El Gráfico 2 en 2D representa un conjunto de datos correspondientes a dos clases distintas. Se puede observar que no hay una línea recta que pueda separar completamente las dos clases de puntos de datos. Por lo tanto, en este caso, se utiliza LDA que reduce el gráfico 2D a un gráfico 1D para maximizar la separabilidad entre las dos clases.




Gráfico 2: Dos clases distintas de un grupo de datos.

En el Gráfico 3 se observa como el análisis discriminante lineal utiliza ambos ejes (X e Y) para crear un nuevo eje y proyecta datos en el mismo de manera tal, que maximiza la separación de las dos categorías y reduce el gráfico 2D a un gráfico 1D. Se puede ver que se genera y traza un nuevo eje (en rojo) en el gráfico 2D de manera que maximiza la distancia entre las medias de las dos clases y minimiza la variación dentro de cada una. En términos simples, este eje recién generado aumenta la separación entre los puntos de datos de las dos clases.




Gráfico 3: Proyección de los datos en el nuevo eje.

Después de generar este nuevo eje utilizando los criterios mencionados anteriormente, todos los puntos de datos de las clases se trazan en el mismo como se muestra en el Gráfico 4.




Gráfico 4 Nuevo eje como resultado de aplicar LDA.

Esto hace que LDA sea particularmente adecuado para tareas de clasificación en las que desea maximizar la separabilidad de clases[39]. El uso combinado de métodos espectroscópicos y LDA está registrado en la literatura como una excelente herramienta para detectar el fraude en los alimentos[40].

El LDA puede manejar conjuntos de datos de alta dimensionalidad, lo cual es especialmente relevante al considerar múltiples características para detectar adulteración. Al analizar estas características en conjunto, el LDA selecciona de manera óptima aquellas que son más relevantes y discriminativas para una clasificación precisa de las muestras.

Otra ventaja del LDA es su capacidad para manejar conjuntos de datos desequilibrados, donde las clases de interés están representadas en proporciones diferentes. En la detección de adulterantes, es común que las clases de muestras auténticas y adulteradas tengan tamaños desiguales. El

LDA se adapta para asignar mayor peso a las clases subrepresentadas, evitando sesgos en la clasificación y asegurando que se utilice la información de todas las clases.

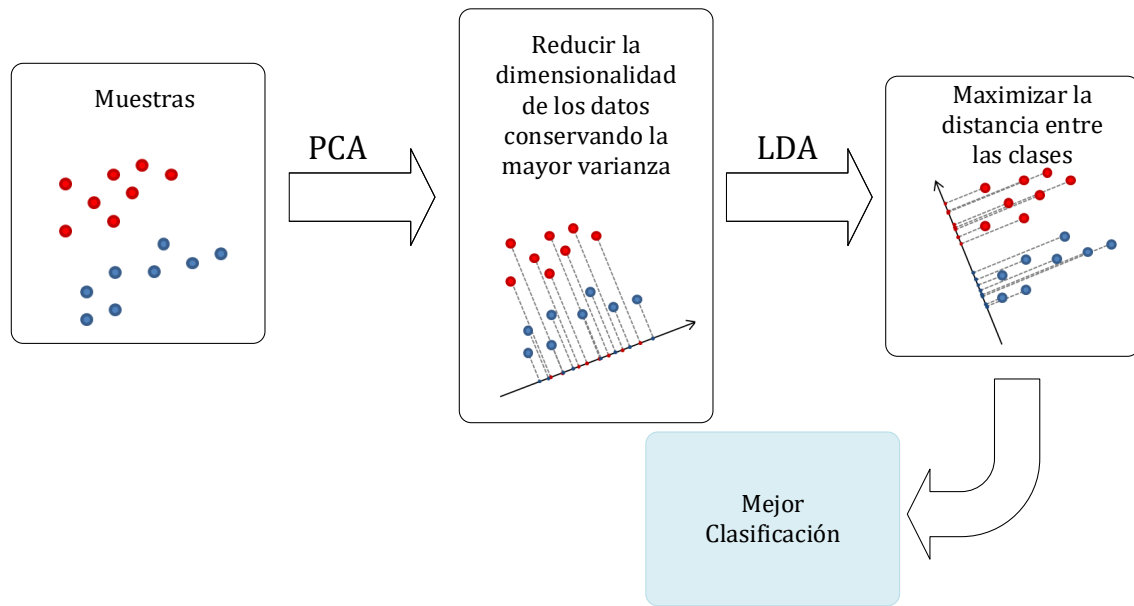
El LDA también tiene limitaciones relacionadas con la correlación entre las características de los datos. Si las características están altamente correlacionadas entre sí, el LDA puede tener dificultades para distinguir las contribuciones individuales de cada característica en la separación de las clases. Esto puede afectar el rendimiento del LDA y comprometer su capacidad para detectar con precisión la adulteración.

En tales casos, es posible que sea necesario aplicar técnicas adicionales de preprocesamiento de datos o selección de características para garantizar un rendimiento óptimo del LDA. Estas técnicas pueden ayudar a reducir la correlación entre las características y resaltar las relaciones más relevantes para la clasificación, mejorando así la capacidad del LDA para detectar fraudes en los alimentos.

A pesar de este desafío, el LDA sigue siendo una valiosa herramienta en la detección de adulterantes. Su capacidad para maximizar la separación entre clases, su adaptabilidad a conjuntos de datos desequilibrados y su manejo de conjuntos de datos de alta dimensionalidad lo hacen una opción poderosa. Al combinar el LDA con técnicas adecuadas de preprocesamiento y selección de características, es posible superar los problemas de correlación y aprovechar al máximo el potencial del LDA en la detección de fraudes alimentarios.

2.3.3 Combinación de PCA y LDA

La implementación de un detector de adulterantes eficiente y preciso implica el procesamiento y análisis de datos complejos. En particular, teniendo en cuenta los análisis realizado anteriormente combinar Análisis de Componentes Principales (PCA) y el Análisis Discriminante Lineal (LDA) en el flujo de trabajo del detector, puede mejorar significativamente la capacidad de detección y clasificación de adulterantes (Ver Esquema 1) [41].



Esquema 1: Combinación de PCA y LDA.

Al aplicar PCA a los datos antes de utilizar el LDA, se logran varias ventajas significativas. PCA elimina las correlaciones y redundancias entre las características, lo que permite representar los datos de manera más compacta y evitar problemas con la matriz de covarianza, que dificultan la aplicación directa de LDA. Se mejora la capacidad de discriminación entre las clases de interés, como las muestras auténticas y las adulteradas en el caso de la detección de adulterantes.

Después de aplicar PCA y reducir la dimensionalidad de los datos, el siguiente paso lógico es utilizar el LDA. El LDA utiliza la estructura discriminativa de los datos para encontrar un hiperplano de proyección que maximice la separación entre las clases. Esto permite identificar las características más discriminativas y enfocarse en la información relevante para una clasificación precisa de las muestras. En el contexto de la detección de adulterantes, el LDA puede ayudar a identificar patrones sutiles de adulteración y mejorar la capacidad del detector para distinguir entre muestras auténticas y adulteradas.

2.4 Conclusiones del capítulo

Como unidad de procesamiento para la implementación del detector de adulterantes se escoge la Raspberry Pi porque es una plataforma de

computación de bajo costo y de propósito general que ofrece una gran flexibilidad en términos de conectividad y expansión. Posee múltiples puertos GPIO (Entrada/Salida de Propósito General) y soporta interfaces como I2C, SPI y UART. Estas características son importantes al considerar la compatibilidad con diferentes sensores y periféricos.

El sensor AS7265x, por su parte, utiliza una interfaz I2C perfectamente compatible con la Raspberry Pi para una comunicación bidireccional que se empleará en la adquisición de datos y el control del sensor.

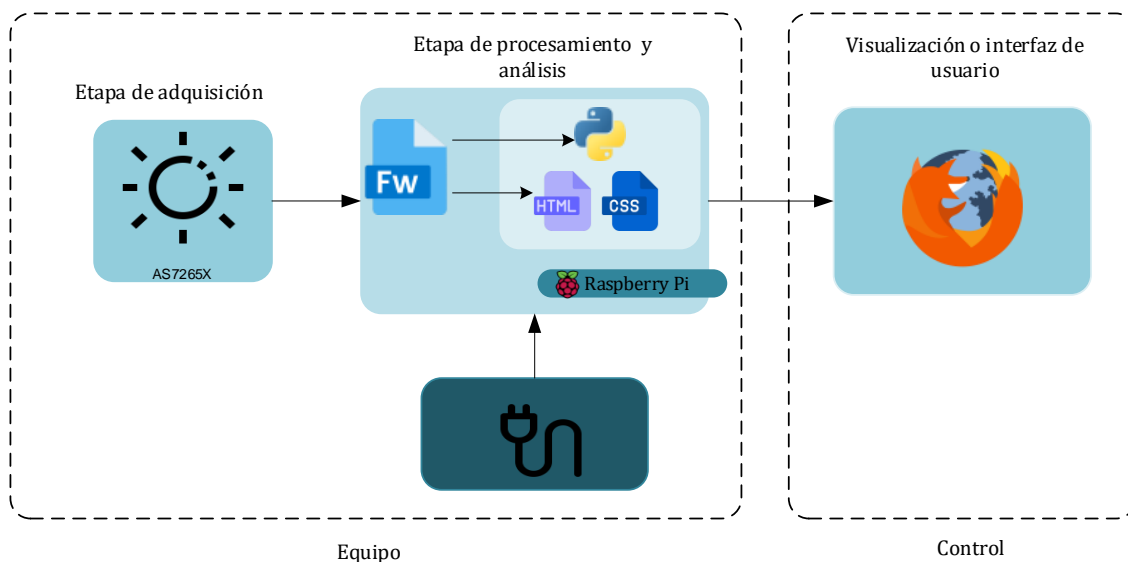
La Raspberry Pi posee la capacidad de procesamiento y almacenamiento necesaria para realizar el análisis de los datos capturados por el sensor, utilizando como lenguaje de programación Python que ofrece una amplia gama de bibliotecas y herramientas que facilitan la implementación de algoritmos de análisis de datos.

Al combinar PCA y LDA, se obtiene una poderosa herramienta para el procesamiento y análisis de datos en la detección de adulterantes. PCA reduce la dimensionalidad y elimina características irrelevantes o ruidosas, lo que simplifica el análisis y mejora la precisión del clasificador. Luego, el LDA se encarga de maximizar la separación entre las clases, identificando las características más discriminativas y mejorando la capacidad de detección y clasificación. Esta combinación permite un enfoque más eficiente y preciso en la detección de adulterantes y mejora la capacidad de tomar decisiones informadas basadas en los datos analizados.

CAPÍTULO III – “DISEÑO E IMPLEMENTACIÓN DEL SISTEMA”

3.1 Diseño del sistema general

El detector espectroscópico de adulterantes en la leche que se diseñó está compuesto por dos partes fundamentales (Ver Esquema 2).




Esquema 2: Diseño general del detector espectroscópico de adulterantes en la leche.

La primera parte está constituida por el equipo que contiene todo el hardware del sistema. En la realización de una predicción se comienza por la etapa de adquisición que es donde se recogen los datos de las muestras medidas, luego esos datos son enviados a la etapa de procesamiento donde son analizados y se obtiene una respuesta con la predicción.

La segunda, es la parte de control y supervisión que consiste en una página web embebida a la que puede acceder el usuario mediante una red Ethernet. Aquí el usuario puede decidir cuándo comenzar una predicción y visualizar los resultados. Además, tiene acceso a los registros de las mediciones realizadas anteriormente y otras funcionalidades que se describen detalladamente más adelante.

3.2 Diseño de Hardware

El diseño de hardware propuesto para el detector espectroscópico de adulterantes en la leche consta de dos componentes principales: el sensor AS7265X y una Raspberry Pi (Ver Esquema 3).



Esquema 3: Hardware del detector espectroscópico de adulterantes en la leche.

A continuación, se describen brevemente los elementos que conforman el hardware del sistema y su interconexión:

- **Sensor AS7265X:** Se utiliza para adquirir los datos de las muestras. El firmware del sensor se encarga de procesar los datos y de entregar los espectros a la Raspberry.
- **Raspberry Pi:** La Raspberry se utiliza como unidad de procesamiento de los datos de entrenamiento y los algoritmos de predicciones en tiempo real. Además, se crea el servidor web utilizando el framework Flask, para acceder a la funcionalidad del detector de adulterantes a través de un navegador web en un dispositivo conectado a la misma red.
- **Alimentación:** La Raspberry Pi es alimentada a través de un adaptador de corriente conectado a su puerto de alimentación micro USB. También es posible alimentarla mediante otros métodos, como a través de pines específicos en su encabezado de GPIO (General Purpose Input/Output). Esto proporciona flexibilidad al diseño, ya que la Raspberry Pi puede recibir energía de diferentes fuentes según las necesidades del

proyecto. El sensor AS7265X es alimentado por los pines de 3.3V y GND de la Raspberry Pi. Esto simplifica el diseño al eliminar la necesidad de una fuente de alimentación adicional para el sensor.

- **Conexión I2C:** El sensor AS7265X se conecta a la Raspberry Pi a través del protocolo de comunicación I2C (Inter-Integrated Circuit). Este permite la transmisión de datos entre dispositivos a través de dos cables, uno para la transmisión de datos (SDA) y otro para el reloj (SCL). La Raspberry Pi actúa como el maestro I2C, mientras que el sensor AS7265X actúa como el esclavo I2C.
 - SDA (Serial Data Line): Es la línea de datos en serie en el protocolo I2C. Se utiliza para la transmisión bidireccional de datos entre el maestro (en este caso, la Raspberry Pi) y el esclavo (el sensor AS7265X). La Raspberry Pi utiliza la línea SDA para enviar comandos de configuración al sensor y recibir los datos espectrales adquiridos. En el diseño del detector espectroscópico, se debe conectar la línea SDA del sensor al pin correspondiente de la Raspberry Pi.
 - SCL (Serial Clock Line): SCL es la línea de reloj serie en el protocolo I2C. Esta línea es controlada por el maestro (Raspberry Pi) y se utiliza para sincronizar la transferencia de datos entre los dispositivos. La Raspberry Pi genera pulsos de reloj en la línea SCL para indicar cuándo se debe leer o escribir en la línea SDA. Tanto el maestro como el esclavo deben operar en la misma frecuencia de reloj. Al igual que con SDA, se debe conectar la línea SCL del sensor al pin correspondiente de la Raspberry Pi.

El funcionamiento del detector espectroscópico sería el siguiente:

- El conjunto de chips AS7265x produce los datos de salida del sensor (ecuación 3.1) basados en los rayos de luz reflejada recibidos desde la muestra o superficie reflectante como se muestra en el Esquema 4.

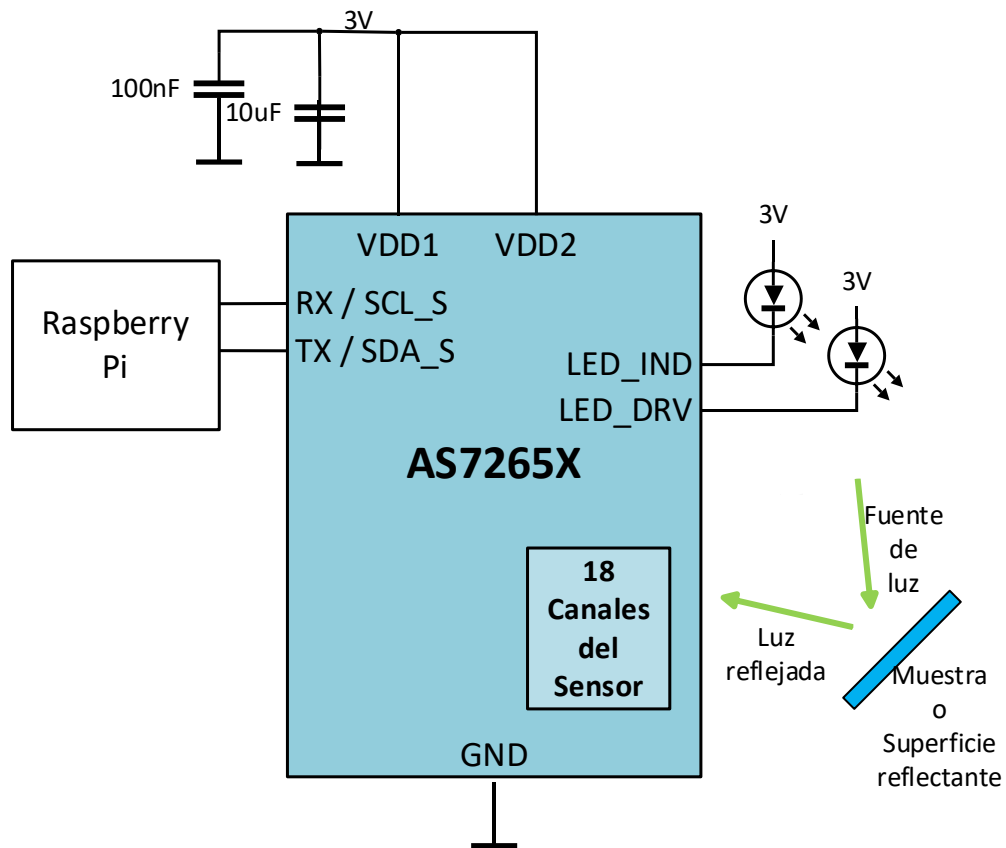
$$\alpha \text{ (canal)} = \sigma - \sigma_1 \quad (3.1)$$

Donde:

σ : Cantidad de luz incidente

σ_1 : Cantidad de luz absorbida

α : Cantidad (recuento) de fotones en el sensor.

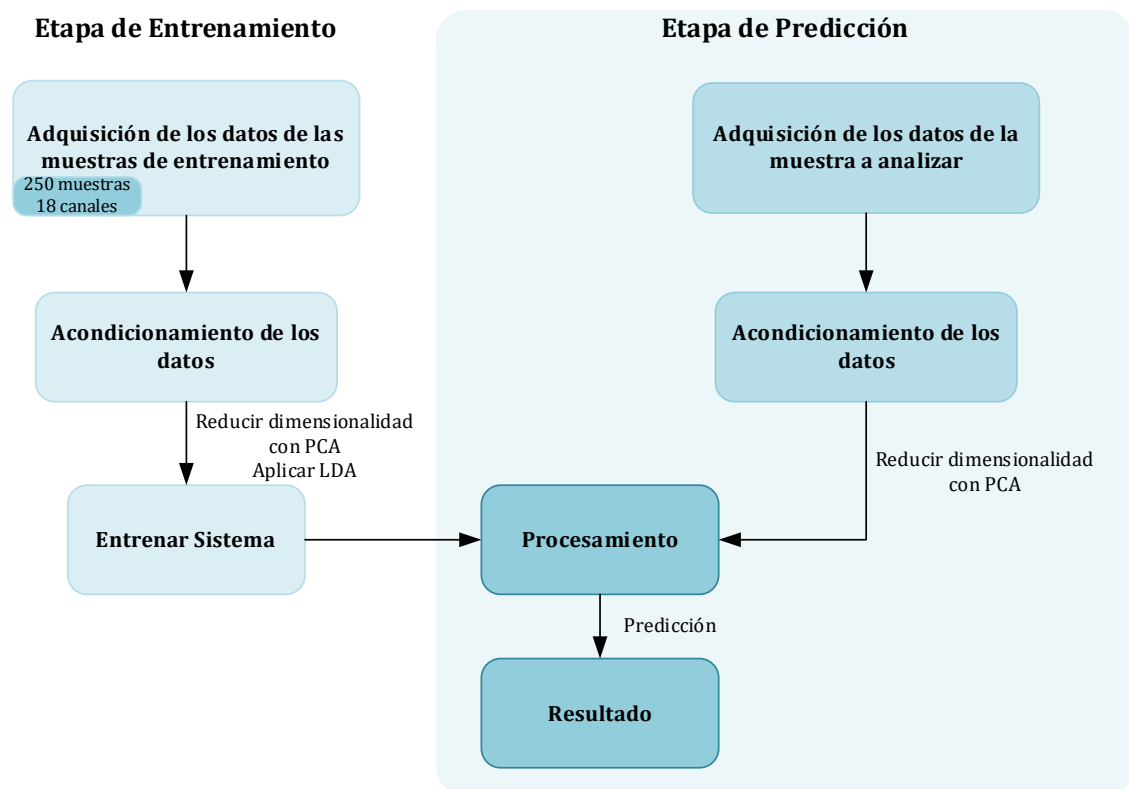


Esquema 4: Funcionamiento del sensor AS7265X.

- La Raspberry Pi inicia la comunicación I2C con el sensor AS7265X enviando una señal de inicio.
- La Raspberry Pi envía comandos y configuraciones al sensor para establecer los parámetros necesarios para la adquisición de datos espectrales.
- El sensor AS7265X recopila los datos espectrales mediante la iluminación de la muestra de leche y la captura de la luz reflejada o transmitida.
- El sensor AS7265X transmite los datos espectrales a la Raspberry Pi a través de la conexión I2C.
- La Raspberry Pi recibe los datos del sensor y realiza el análisis correspondiente utilizando algoritmos y técnicas específicas para detectar adulterantes en la leche.

3.3 Diseño del Firmware

El firmware del detector espectroscópico de adulterantes en la leche se realizó utilizando Python como lenguaje de programación y está dividido en dos etapas fundamentales, la etapa de entrenamiento y la etapa de predicción (Ver Esquema 5), a continuación, se realiza un análisis detallado de cada una de las etapas.



Esquema 5: Funcionamiento del firmware del detector espectroscópico de adulterantes en la leche.

Etapa de entrenamiento:

1. **Adquisición de datos:** Se utiliza la librería "smbus" para adquirir los datos espectrales de la muestra utilizando la comunicación I2C entre la Raspberry Pi y el sensor AS7265X. Se adquieren 250 muestras de 18 canales utilizando el sensor AS7265X, cada muestra corresponde al promedio de 5 escaneos del sensor y se almacenan en un archivo CSV (Comma-Separated Values) para su posterior análisis.
2. **Acondicionamiento de los datos:** Los datos almacenados en el archivo CSV se leen utilizando la librería "pandas". Los datos se someten a

acondicionamiento para mejorar su calidad, esto se trata de la derivación de los datos y la aplicación de un filtro de suavizado (Savitzky–Golay en este caso) utilizando la librería “**scipy**” para reducir el ruido y mejorar la señal.

Antes de aplicar PCA y LDA, se escalan los datos utilizando el objeto “StandardScaler” de la librería “**scikit-learn**”, para asegurar que todas las características tengan una influencia comparable durante el análisis. El escalado se realiza restando la media de cada característica y dividiendo por su desviación estándar. Esto asegura que todas las características tengan una media cero y una desviación estándar de 1. El escalado es importante para evitar que características con magnitudes mucho mayores dominen el análisis.

3. Análisis de datos mediante PCA: Para realizar el análisis de componentes principales (PCA), con el fin de reducir la dimensionalidad de los datos y extraer las características más relevantes de las muestras, se utiliza la librería “scikit-learn” en Python. Al aplicar PCA, obtenemos una serie de componentes principales ordenados en función de su capacidad para explicar la variabilidad en los datos. Los componentes principales se calculan de tal manera que el primero captura la mayor varianza en los datos, el segundo la siguiente mayor varianza y así sucesivamente.
4. Análisis de datos mediante LDA: El análisis discriminante lineal (LDA) también se implementa utilizando la librería “scikit-learn”, que incluye métodos y funciones específicas para el análisis de discriminantes lineales. LDA utiliza información sobre las clases de las muestras para encontrar una combinación lineal de características que maximice la separación entre las clases. Busca proyectar los datos en un espacio de menor dimensión de tal manera que las muestras de la misma clase se agrupen cercanas entre sí, mientras que las muestras de diferentes clases se separen.
5. Entrenamiento del sistema de predicción: Utilizando los resultados de PCA y LDA, se entrena el sistema de predicción, que aprenderá a distinguir entre las distintas muestras. El modelo o algoritmo de

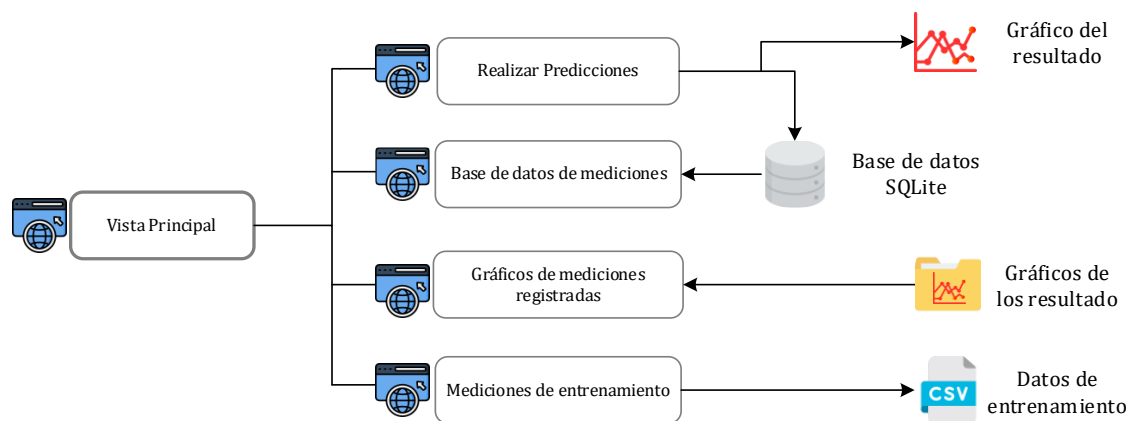
entrenamiento se guarda para su uso posterior utilizando las funciones de serialización de "pickle".

Etapas de predicción:

1. Adquisición de datos de la muestra a analizar: Al igual que en la etapa de entrenamiento, se utiliza la librería "smbus" para adquirir los datos espectrales de la muestra utilizando la comunicación I2C entre la Raspberry Pi y el sensor AS7265X. Se obtienen 18 valores de longitud de onda que corresponden al promedio de 5 escaneos del sensor y conforman el espectro de la muestra.
2. Conversión y acondicionamiento de datos: Utilizando las mismas librerías y técnicas empleadas en la etapa de entrenamiento, se derivan los datos utilizando el filtro de suavizado y se escalan utilizando el mismo objeto "StandardScaler" para que sean compatibles con el modelo de predicción.
3. Reducción de dimensionalidad con PCA: Se utiliza la misma implementación de PCA, utilizando la librería "scikit-learn", para reducir la dimensionalidad de los datos de la muestra a analizar, al mismo número de componentes principales que se redujeron los datos de entrenamiento.
4. Realizar la predicción: La predicción se realiza utilizando la función "predict" del modelo LDA ya entrenado. Se le pasa como argumento el resultado de aplicar PCA a los datos de la muestra analizada y se obtiene como resultado la etiqueta correspondiente de la clase a la que pertenece la muestra desconocida.

3.4 Diseño de la página

Para el diseño de la página web del detector de adulterantes se utilizó Flask. Este permite la implementación de la página web del detector de adulterantes para gestionar las rutas, renderizar plantillas HTML, interactuar con formularios, comunicarse con la base de datos y permitir la integración de gráficos. (Ver Esquema 6).



Esquema 6: Funcionamiento de la página web del detector espectroscópico de adulterantes en la leche.

La página web del detector de adulterantes ofrece una interfaz intuitiva y fácil de usar con un menú principal que consta de cuatro opciones como se muestra en la Figura 11.




Figura 11: Vista principal la página del detector espectroscópico de adulterantes en la leche.

Realizar una nueva medición: Esta opción permite a los usuarios realizar una medición de una muestra en tiempo real y detectar la presencia de adulterantes. Al seleccionar esta opción, se mostrará una interfaz donde el usuario deberá ingresar los datos pedidos y podrá interactuar con el sensor ejecutando la orden de realizar una medición (Ver Figura 12). Estos datos se analizarán utilizando el sistema de predicción desarrollado previamente y se

mostrará como resultado un gráfico que contiene el espectro de la medición realizada y el resultado de la predicción.



Figura 12: Opción de la página web que permite realizar una predicción en tiempo real.

Registro de mediciones: En esta opción del menú, los usuarios pueden acceder a una tabla que contiene el registro de todas las mediciones realizadas. La tabla mostrará información relevante sobre cada una de ellas, como: la fecha y hora, los resultados de detección y cualquier otra información adicional recopilada. Además, se proporcionará un campo de búsqueda que permitirá filtrar las mediciones por cualquier campo de la tabla, lo que facilita la búsqueda y el análisis de mediciones anteriores (Ver Figuras 13 y 14).

Base de Datos

Canal:	<input type="text"/>
Longitud de Onda:	<input type="text"/>
Valor:	<input type="text"/>
Fecha:	<input type="text"/>
Hora:	<input type="text"/>
ID:	<input type="text"/>
Prediccion:	<input type="text"/>
<input type="button" value="Filtrar"/>	

Figura 13: Campo de búsqueda en la tabla que registra las mediciones del detector espectroscópico de adulterantes en la leche.

Filtrar

Canal	Longitud de Onda	Valor	Fecha	Hora	ID	Prediccion
A	410nm	291.0768127441406	02/06/23	14:55:25	A	PURA
B	435nm	67.83019409179687	02/06/23	14:55:25	A	PURA
C	460nm	128.23863220214844	02/06/23	14:55:25	A	PURA
D	485nm	57.6453742980957	02/06/23	14:55:25	A	PURA
E	510nm	83.62670135498047	02/06/23	14:55:25	A	PURA
F	535nm	114.101025390625	02/06/23	14:55:25	A	PURA
G	560nm	24.16608238220215	02/06/23	14:55:25	A	PURA
H	585nm	24.802637100219727	02/06/23	14:55:25	A	PURA
I	610nm	174.68905029296874	02/06/23	14:55:25	A	PURA
J	645nm	15.990631103515625	02/06/23	14:55:25	A	PURA
K	680nm	44.501007080078125	02/06/23	14:55:25	A	PURA
L	705nm	5.4178900718688965	02/06/23	14:55:25	A	PURA
R	730nm	12.891751289367676	02/06/23	14:55:25	A	PURA
S	760nm	8.955801010131836	02/06/23	14:55:25	A	PURA
T	810nm	20.931793212890625	02/06/23	14:55:25	A	PURA
U	860nm	45.66881561279297	02/06/23	14:55:25	A	PURA
V	900nm	14.534440994262695	02/06/23	14:55:25	A	PURA
W	960nm	5.757560729980469	02/06/23	14:55:25	A	PURA

Figura 14: Tabla que registra los datos de una medición realizada por el detector espectroscópico de adulterantes en la leche.

Gráficos de mediciones: Esta opción permitirá a los usuarios visualizar una lista de gráficos que representan las mediciones realizadas (Ver Figura 15) y poder visualizar cualquiera de ellos haciendo clic en **“(ver)”** como se muestra en la Figura 16. Cada gráfico mostrará la información espectral de una medición específica y el resultado de la predicción, lo que proporcionará una representación visual de los datos. Los usuarios podrán seleccionar cualquier gráfico de la lista para ampliarlo y examinarlo con más detalle. Esto permitirá un análisis visual más profundo de las mediciones realizadas y ayudará en la detección de patrones o anomalías en los datos espectrales.

Gráficos disponibles:

1. M4(leche_al_75).svg (ver)
2. M11(leche_al_25).svg (ver)
3. M5(lagua).svg (ver)
4. M3_leche_al_50(leche_al_50).svg (ver)
5. M1_pura(pura).svg (ver)

Figura 15: Vista de la página que muestra la lista con los gráficos de las mediciones realizadas.

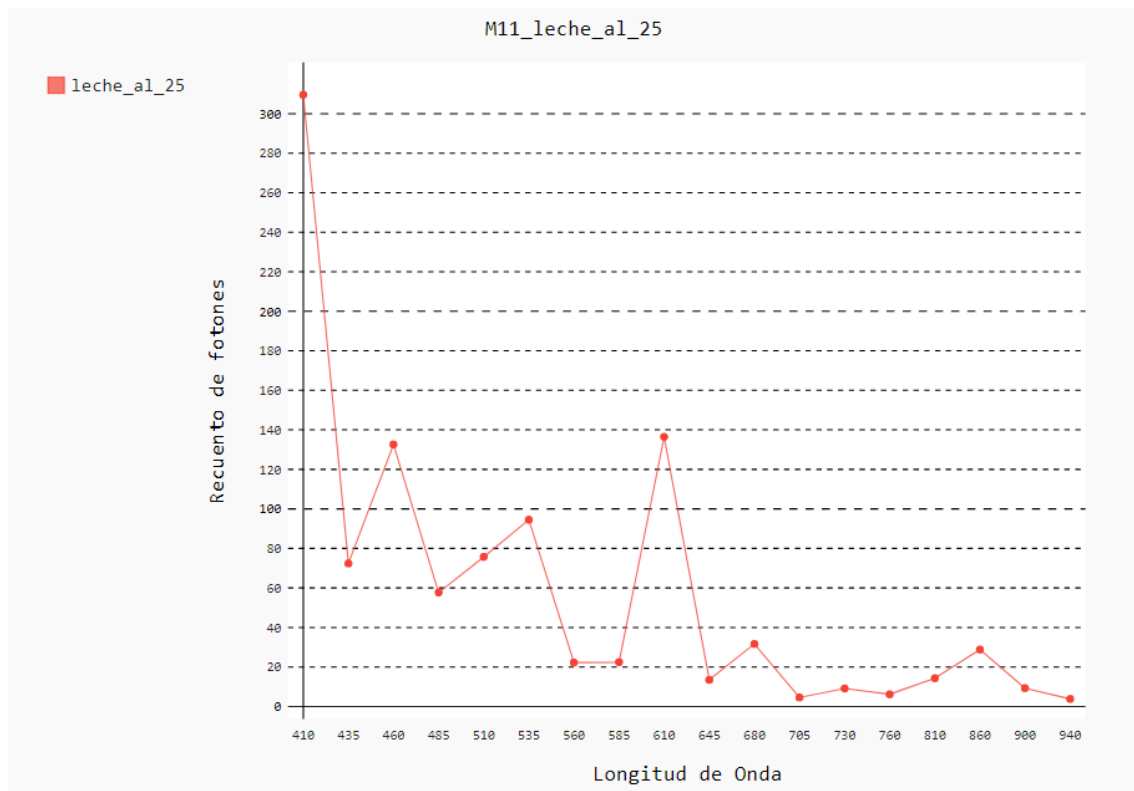


Figura 16: Espectro y resultado de predicción almacenado de una muestra.

Medición para entrenamiento: La cuarta opción del menú está destinada a los usuarios que deseen realizar mediciones con el propósito de entrenar el detector de adulterantes. Al seleccionar esta opción, se mostrará una interfaz similar a la opción de medición en tiempo real, pero en este caso los usuarios deberán ingresar que adulterante contiene la muestra de leche analizada (Ver Figura 17).

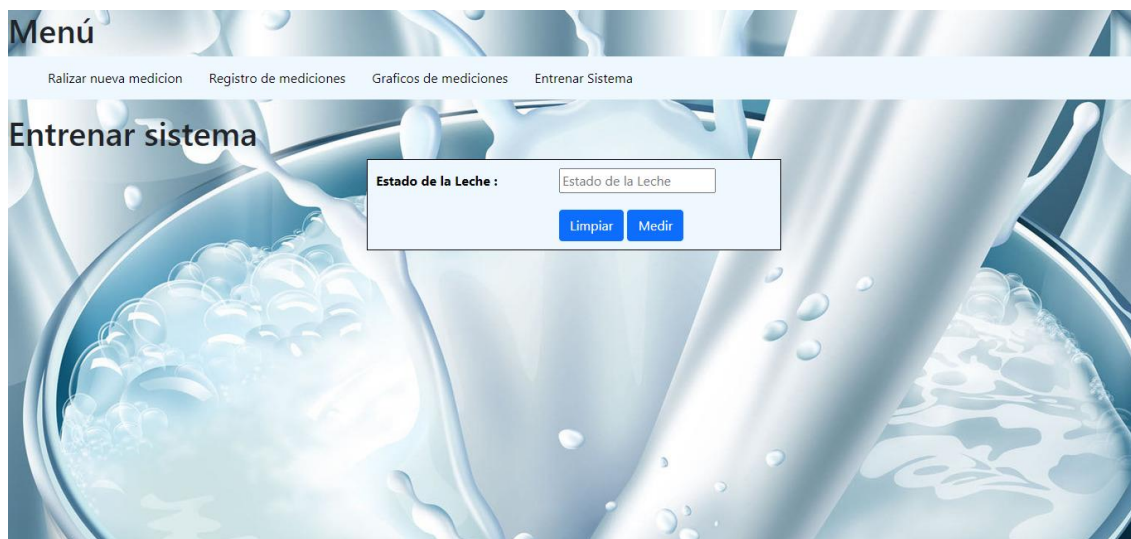


Figura 17: Opción de la página web del detector de adulterantes que permite realizar mediciones para entrenar el sistema.

3.5 Preparación de las muestras para las mediciones de entrenamiento

Para entrenar el sistema y probar la precisión del detector espectroscópico de adulterantes en la leche se dividió el experimento en dos etapas, a la primera se le denominó Grupo A. Esta consiste en cinco muestras, cuatro de ellas corresponden a una preparación de leche en polvo con diferentes concentraciones de agua y la quinta es agua solamente. La leche que se tomó como pura (primera muestra) se preparó disolviendo 30ml de leche en polvo en 160ml de agua. La segunda muestra consiste en la misma fórmula, pero esta vez rebajada con un 25% más de agua. La tercera fue rebajada con un 50% más de agua, la cuarta con un 75% y finalmente la quinta es 100% agua (Ver Gráfico 5).




Gráfico 5: Concentración de las muestras del Grupo A.

Las mediciones de cada una de las muestras (clases) de este primer grupo se realizaron en un frasco transparente (Ver figura 18) llenándolo con 30ml de muestra. Con esto se garantiza que la distancia entre el sensor y la muestra durante las mediciones sea siempre la misma y menor a una 2.54cm que es la distancia óptima para el sensor AS7265x según el datasheet del fabricante[27]. Se registraron en esta etapa del experimento, 250 mediciones bajo condiciones de luz artificial en la habitación, 50 de cada clase y cada una correspondía al promedio de 5 escaneos del sensor (Ver Figura 19).



Figura 18: Frasco utilizado para las mediciones del Grupo A.



Figura 19: Medición bajo luz artificial en la habitación.

En la segunda etapa del experimento denominada Grupo B se tomaron igualmente 5 muestras, la primera era leche de vaca pura, la segunda, leche de vaca rebajada con un 25% de agua, la tercera con un 50%, la cuarta con un 75% y finalmente la quinta solo agua (Ver Gráfico 6).




Gráfico 6: Concentración de las muestras del Grupo B.

Se garantizó también que la distancia entre el sensor y la muestra fuera menor a una 2.54cm. Esta vez el experimento se realizó sin luz externa en el ambiente y además se utilizó un frasco negro opaco con el fin de evitar interferencias en las mediciones por parte de la luz externa y reflejo del frasco (Ver Figura 20).

Se registraron 250 mediciones, 50 de cada clase y cada una correspondía al promedio de 5 escaneos del sensor (Ver Figura 21).



Figura 20 Frasco utilizado para las mediciones del Grupo B.



Figura 21: Medición sin luz en la habitación.

3.6 Análisis de los resultados obtenidos

En este epígrafe se realizará un análisis de los datos de entrenamiento del Grupo A y Grupo B con el fin de poder evaluar el comportamiento del detector espectroscópico de adulterantes en la leche propuesto.

3.6.1 Selección del número de componentes principales óptimo para reducir la dimensionalidad de los datos.

Utilizando PCA se va a reducir la dimensionalidad de los datos de 18 características a un número menor. Cada componente principal revelará parte de la variación en los datos. El primer componente principal revelará la mayor parte de la variación, el segundo un poco menos, y así sucesivamente. La suma de las varianzas de todos los componentes principales se denomina varianza total[34].

Para seleccionar el número de componentes principales que representan la mayor parte de las variaciones de los datos, se realizaron los gráficos de la varianza explicada y la varianza acumulada de los primeros 10 componentes principales extraídos de los datos del Grupo A (ver Gráfico 7) y Grupo B (ver Gráfico 8).

La varianza explicada se refiere a la proporción de la varianza total de los datos que es explicada por cada componente principal. Cada componente principal captura una cierta cantidad de información o variabilidad presente en los datos originales. La varianza explicada de un componente principal indica cuánta información o varianza se conserva al retener ese componente en el análisis. Se calcula como el cociente entre la varianza del componente principal y la varianza total de los datos.

Por otro lado, la varianza acumulada es la suma acumulativa de las varianzas explicadas de los componentes principales en PCA. Representa la cantidad total de varianza de los datos que se conserva al retener una cierta cantidad de componentes principales. La varianza acumulada es útil para determinar cuántos componentes principales se deben retener para capturar una cantidad deseada de información o varianza.

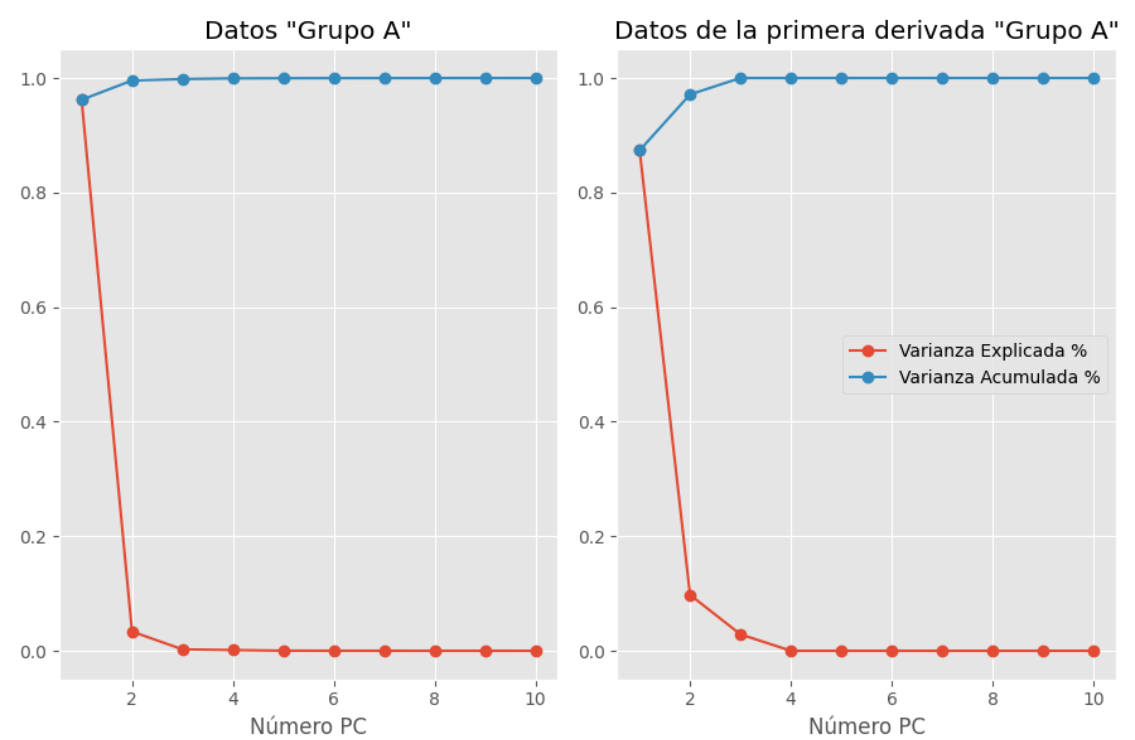


Gráfico 7: Varianza explicada y varianza acumulada de los datos (a la izquierda) y los datos derivados (a la derecha) del Grupo A.

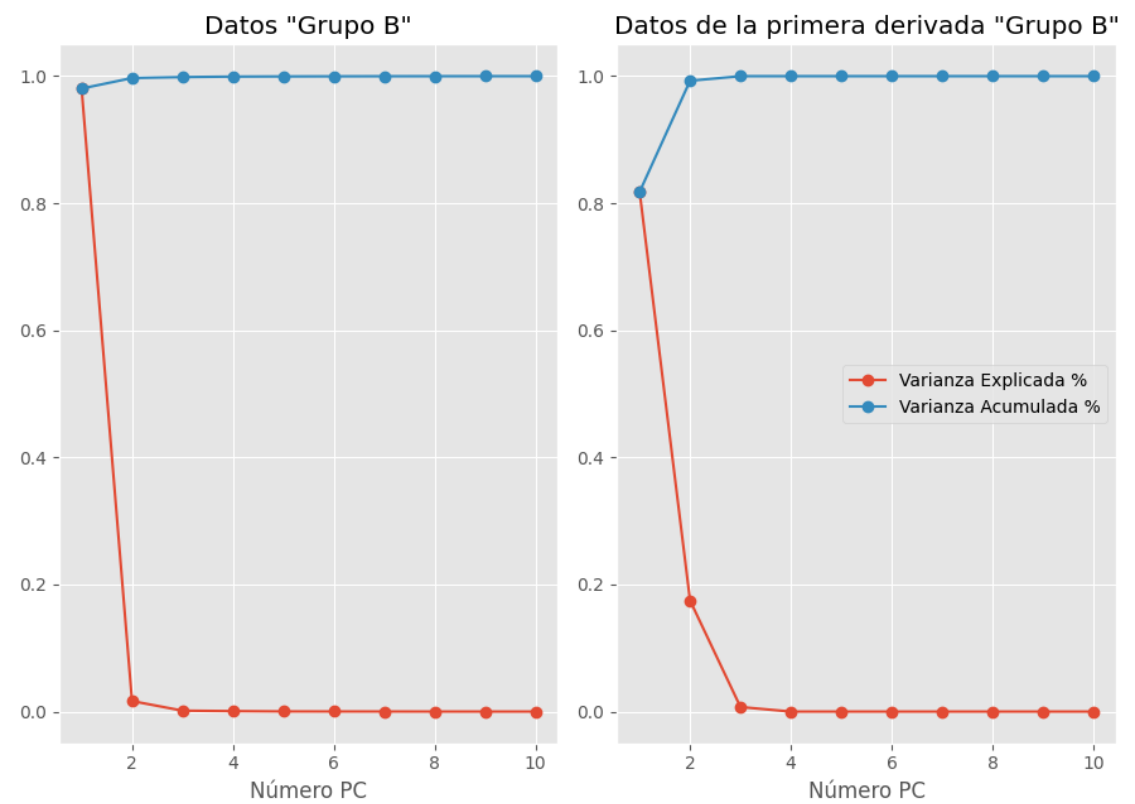


Gráfico 8: Varianza explicada y varianza acumulada de los datos (a la izquierda) y los datos derivados (a la derecha) del Grupo B.

Para realizar una clasificación más precisa se utilizarán en el entrenamiento del clasificador los datos derivados, ya que la derivación puede resaltar características o patrones relevantes en los datos que no son tan evidentes en los datos originales. La derivación es una operación matemática que calcula las tasas de cambio o las diferencias entre puntos de datos adyacentes.

Esto puede ayudar a aumentar la separabilidad de las clases en el espacio de características y hacer que las diferencias entre las muestras sean más distintivas. Lo que es especialmente útil, en problemas de clasificación donde las clases son intrínsecamente similares o tienen solapamientos en el espacio de características original.

Sin embargo, es importante tener en cuenta que la derivación también puede introducir ruido adicional en los datos. Por lo tanto, es necesario aplicar técnicas de filtrado o suavizado para reducir el ruido y eliminar las fluctuaciones no deseadas que podrían afectar negativamente la precisión de la clasificación.

Es importante tener en cuenta que el filtro de suavizado no elimina el ruido por completo y puede introducir cierto grado de pérdida de información. Por lo tanto, al seleccionar el número de componentes principales, se utilizará el gráfico de los datos sin derivar, ya que proporciona una representación más precisa de la variabilidad subyacente y evita la amplificación del ruido introducido por la derivación[34].

Observando la varianza acumulada de los datos espectrales sin derivar en los gráficos anteriores, se eligen cuatro componentes principales para el Grupo A y para el Grupo B, ya que en estos están representadas la mayoría de las variaciones de los datos. Esto se muestra en los gráficos 9 y 10 que contienen una ampliación de la varianza acumulada de los gráficos anteriores.




Gráfico 9: Varianza acumulada de los datos del Grupo A.




Gráfico 10: Varianza acumulada de los datos del Grupo B.

3.6.2 Aplicación de PCA en los datos para entrenamiento

A continuación, se muestran los gráficos de puntuación de los cuatro primeros componentes principales de los datos derivados del Grupo A (Gráfico 11) y Grupo B (Gráfico 12) agrupados por clases en dos dimensiones. Cada punto en los diagramas anteriores representa una medición individual. Los puntos están codificados por colores según la composición de la muestra a la que pertenecen.

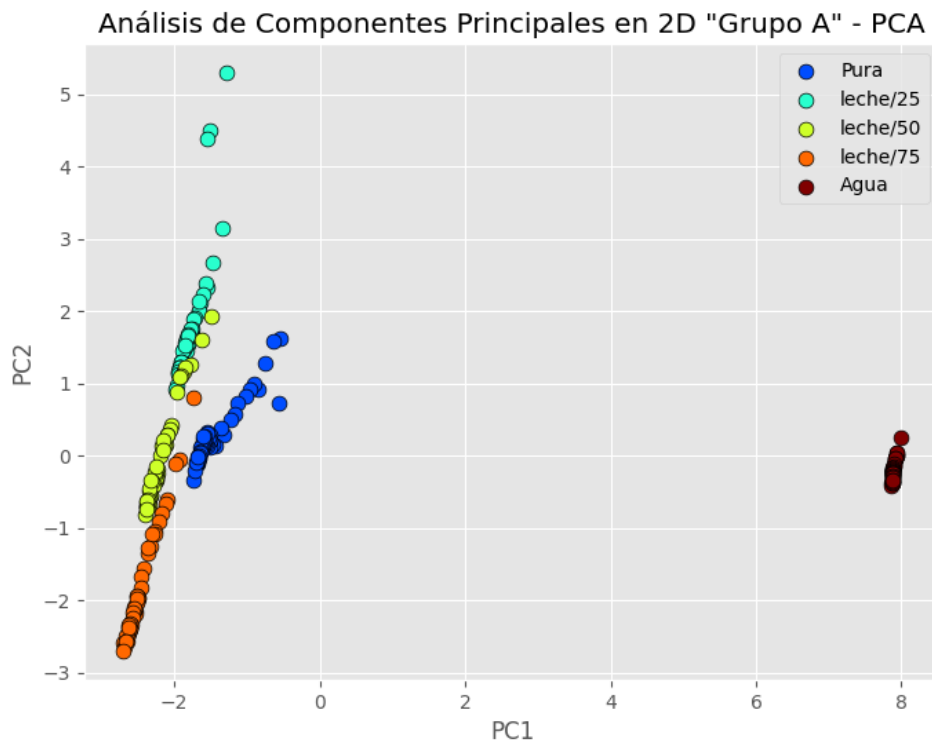


Gráfico 11: mediciones de entrenamiento del Grupo A después de aplicar PCA.

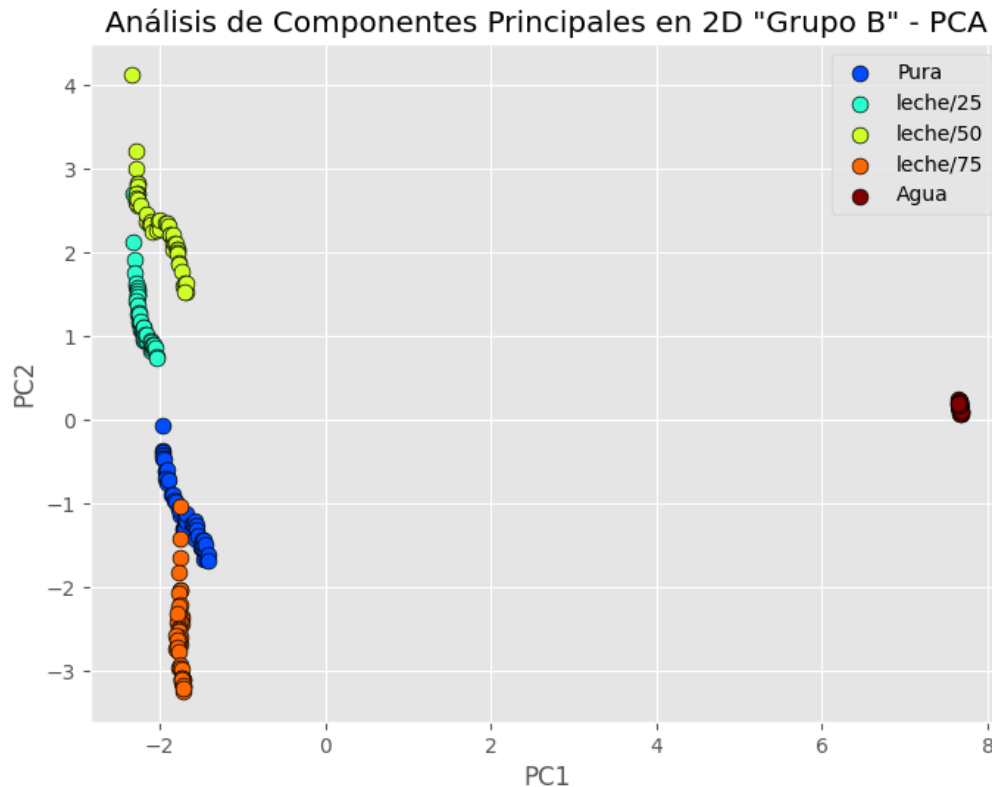


Gráfico 12: Mediciones de entrenamiento del Grupo B después de aplicar PCA.

Es importante tener en cuenta que después de realizar PCA los datos tienen cuatro dimensiones, por lo tanto, los gráficos anteriores no muestran toda la información contenida en los datos, solamente una proyección de los datos en el plano (PC1; PC2). Pero sí es suficiente para poder observar de manera visual, como quedan agrupadas las clases después de aplicar PCA.

3.6.3 Aplicación de LDA a los datos procesados con PCA

A continuación, se muestran los resultados de aplicar LDA a los datos procesados con PCA del Grupo A (Gráfico 13) y del Grupo B (Gráfico 14).




Gráfico 13: Clases del Grupo A después de aplicar LDA.




Gráfico 14 Clases del Grupo B después de aplicar LDA.

Es importante tener en cuenta que estos gráficos en 2D tampoco muestran toda la información de los datos (que tienen cuatro dimensiones), son una proyección en el plano (LD1; LD2). Se puede observar como la aplicación de LDA aumentó considerablemente la distancia entre las clases, lo que eleva la eficiencia del sistema de predicción.

3.6.4 Cálculo de la precisión del clasificador

Para calcular la precisión del clasificador se dividen los datos en dos conjuntos. El 75% de los datos se utiliza para entrenar el sistema y el otro 25% se usa como prueba para realizar predicciones con esos valores de mediciones, ya conociendo a que tipo de muestra pertenecen y pudiendo comprobar si es correcta o no la predicción realizada. De esta manera se calcula el porcentaje de efectividad en las predicciones utilizando la validación cruzada. Este procedimiento se realiza cuatro veces, utilizando cada vez un 25% de los datos diferente para las pruebas y el resto para entrenamiento[42].

De esta manera se obtuvo un promedio de acierto en las predicciones de las muestras del Grupo A (disolución de leche en polvo) de 96.77% (+/- 4.85%) y en las del Grupo B (disolución de leche de vaca) un promedio de 99.47% (+/- 1.84%), un resultado bastante satisfactorio.




Gráfico 15: Efectividad en las predicciones del Grupo A y Grupo B.

3.6.5 Comprobación de los resultados obtenidos en la realización de predicciones utilizando muestras conocidas.

A continuación, se presentan los resultados de la predicción utilizando muestras previamente conocidas, no utilizadas en el entrenamiento del clasificador, con el fin de probar la eficiencia del detector implementado.

Se realizó una medición de una muestra previamente conocida, primeramente, se insertó el nombre de la muestra **M1_pura** (muestra 1 de la disolución de leche en polvo que se definió como pura) y luego se ingresó en el ID el Grupo **A** (grupo que corresponde a disolución de leche en polvo) (Ver Figura 22). Se procedió a realizar la medición donde el sensor adquirió los datos (se marcó el botón de medir).



Figura 22: Datos que se ingresaron para la realización de una muestra de leche pura del Grupo A.

Luego de realizar la medición, la página (Ver Figura 23) muestra el resultado de la predicción realizada en tiempo real. El gráfico corresponde al espectro de la muestra tomada. En la parte superior aparece el nombre de la muestra (**M1_pura**) y a la izquierda el resultado de la predicción (**pura**) hecha por el detector que coincide con lo esperado.




Figura 23: Resultado de la predicción y espectro de la muestra analizada del Grupo A.

La Figura 24 corresponde a otra medición realizada, siguiendo la misma metodología anterior, con el fin de comprobar la precisión del clasificador. Esta vez la muestra corresponde al Grupo B (Disolución de leche de vaca pura). Se inició insertando el nombre de la muestra **M3_leche_al_50** (muestra 3 de leche vaca disuelta en un 50% de agua). En la figura se puede observar que el resultado devuelto por el detector es el esperado (leche_al_50). Luego se ingresó en el ID el Grupo B. Se procedió a realizar la medición donde el sensor adquirió los datos (se marcó el botón de medir).



Figura 24: Datos que se ingresaron para la realización de una muestra de leche pura del Grupo B.

La página (Ver Figura 25) muestra el resultado en tiempo real de la predicción. El gráfico corresponde al espectro de la muestra tomada. Aparece el nombre de la muestra (**M3_leche_al_50**) en la parte superior y a la izquierda el resultado de la predicción (**leche_al_50**) hecha por el detector, coincidiendo nuevamente con lo esperado.




Figura 25 Resultado de la predicción y espectro de la muestra analizada del Grupo B.

3.7 Conclusiones del capítulo

Con el análisis de este capítulo se puede concluir que la selección del sensor AS7265X y la Raspberry Pi como plataforma de control, simplifican el diseño

del sistema. Debido a que puede alimentar el sensor y su capacidad de comunicación a través del protocolo I2C para recibir datos del sensor.

La combinación de PCA y LDA en el proceso de análisis de los datos espectrales ha permitido obtener un modelo más robusto y preciso para la detección de adulterantes en la leche. Al reducir la dimensionalidad de los datos con PCA para resolver el problema de la colinealidad de los datos y luego aplicar LDA, se logra una representación más discriminativa y se mejora la separabilidad entre las clases, lo que aumenta la capacidad del sistema para identificar y clasificar correctamente las muestras.

Al comparar los dos grupos distintos de muestras utilizadas para entrenar el sistema, se observó que aquellas realizadas sin luz externa en un entorno controlado y utilizando un frasco opaco (Grupo B) para evitar la interferencia de la luz ambiente; tuvieron un mayor porcentaje de efectividad en las predicciones en comparación con las muestras realizadas bajo condiciones de luz artificial y utilizando un frasco transparente (Grupo A), que reflejaba la misma luz del sensor durante las mediciones (Ver Gráfico 15).

Estos resultados sugieren que las condiciones ambientales y los elementos utilizados durante la adquisición de las muestras pueden influir significativamente en la precisión y confiabilidad del detector. Al evitar la luz externa y utilizar un frasco opaco, se minimiza la posibilidad de interferencia y se logra una medición más precisa de los espectros de las muestras. Por lo tanto, es importante establecer condiciones de adquisición de muestras controladas y consistentes para obtener resultados óptimos en el clasificador.

La implementación del detector ha permitido la detección eficiente y precisa de adulterantes en la leche. La combinación del hardware, el firmware y la página web desarrollados, ha creado un sistema integral que proporciona a los usuarios una experiencia interactiva, útil y de fácil acceso. Con el uso de tecnologías como Python, Flask y herramientas de análisis de datos como PCA y LDA, se ha logrado un detector efectivo y adaptable para abordar el problema de adulteración en la leche.

CAPÍTULO IV – “ANÁLISIS ECONÓMICO Y DE VIABILIDAD DEL PROYECTO”

En este capítulo, se realizará el análisis económico del proyecto donde se mostrarán los costos y recursos empleados. Con el fin de evaluar la viabilidad del proyecto.

4.1 Cálculo de los costos de resultados de la investigación

El cálculo del costo de la investigación se realiza al inicio del proyecto para determinar un estimado del costo real del mismo. Este se determina mediante los costos directos e indirectos de la investigación.

$$CT = CD + CI \quad (4.1)$$

Dónde: CT: Costo total. CD: Costo Directo. CI: Costo Indirecto.

4.1.1 Cálculo del costo directo

Los costos directos están determinados por concepto de salarios, materiales directos, dietas, pasajes y otros gastos. Se determinan mediante la ecuación:

$$CD = SB + SC + SS + MD + DP + OG \quad (4.2)$$

Dónde:

SB: Salario Básico. SC: Salario Complementario. SS: Seguridad Social. MD: Material Directos. DP: Dietas y Pasajes. OG Otros Gastos.

4.1.1.1 Salario básico

El salario básico es el salario que se le paga a los adiestrados por el tiempo dedicado a la investigación sin incluir vacaciones ni seguridad social. Incluye los salarios básicos de todos los participantes en la elaboración del proyecto y se determina mediante la ecuación:

$$SB = \sum (ai * bi) n \quad (4.3)$$

Dónde:

a_i : Días dedicados a la investigación por participantes

b_i : Salario diario del participante (salario mensual/24)

n : Número total de participantes

- Autor a_1 , b_1 , SB_1 :

$$a_1: 138 \text{ días} * 1 \text{ autor} = 138 \text{ días}$$

$$b_1: \frac{870,00 \text{ CUP}}{24} = 36,25 \text{ CUP}$$

$$SB_1: (138 \text{ días} * 36,25 \text{ CUP}) * 1 \text{ autor} = 5.002,5 \text{ CUP}$$

- Tutor de la Universidad a_2 , b_2 , SB_2 :

$$a_2: 95 \text{ días} * 1 \text{ autor} = 95 \text{ días}$$

$$b_2: \frac{9.560,00 \text{ CUP}}{24} = 398,33 \text{ CUP}$$

$$SB_2: (95 \text{ días} * 398,33 \text{ CUP}) * 1 \text{ autor} = \$37.841,35 \text{ CUP}$$

$$SB = SB_1 + SB_2$$

$$SB = 5.002,5 \text{ CUP} + \$37.841,35 \text{ CUP}$$

$$SB = 42.843,85 \text{ CUP}$$

4.1.1.2 Salario Complementario

El salario complementario está destinado al pago de las vacaciones, siendo el 9,09% del salario básico. Este se determina mediante la ecuación:

$$SC = 0,0909 * SB \quad (4.4)$$

$$SC = 0,0909 * 42.843,85 \text{ CUP}$$

$$SC = 3.894,5 \text{ CUP}$$

4.1.1.3 Seguridad social

La seguridad social equivale al 12,5 % de la suma del salario básico más el salario complementario. Se calcula a través de la ecuación:

$$SS = 0,125 * (SB + SC) \quad (4.5)$$

$$SS = 0,125 * (42.843,85 \text{ CUP} + 3.894,5 \text{ CUP})$$

$$SS = 5.842,294 \text{ CUP}$$

4.1.1.4 Gastos por medios o materiales directos

El gasto por materiales directos se refiere a los materiales utilizados directamente en la investigación, dígase equipos, componentes, materiales, entre otros que se incorporan definitivamente al resultado de la investigación. La Tabla 4 muestra los componentes electrónicos y herramientas de desarrollo utilizadas, su precio en moneda nacional y en USD, teniendo en cuenta que la tasa de cambio del USD es 120.

Tabla 4: Precio de los componentes de Hardware del detector diseñado.

Materiales	Precio USD	Precio CUP
Tarjeta Micro SD 16 GB	\$4,99	598,8 CUP
Raspberry Pi 3 Modelo B	\$89,99	10.799 CUP
Sensor AS7265X	\$69,99	8.398,8 CUP

En este caso:

$$MD = 598,8 \text{ CUP} + 10.799 \text{ CUP} + 8.398,8 \text{ CUP}$$

$$MD = 19.796,6 \text{ CUP}$$

4.1.1.5 Dietas y pasajes

Dietas y pasajes se refiere al presupuesto empleado en la alimentación o el transporte. En este caso el gasto es cero.

4.1.1.6 Otros gastos

Otros gastos se refieren a los ocasionados por concepto de uso de máquina u otro equipamiento, en el cual cada hora de trabajo equivale a 10,00 CUP y se determina mediante la ecuación:

$$OG = cant. \text{ días} * cant. \text{ horas} * 10,00 \text{ CUP} \quad (4.6)$$

$$OG = 138 \text{ días} * 6 \text{ horas} * 10,00 \text{ CUP}$$

$$OG = 8.280 \text{ CUP}$$

Cálculo del costo directo

$$CD = SB + SC + SS + MD + DP + OG \quad (4.7)$$

$$CD = 42.843,85 \text{ CUP} + 3.894,5 \text{ CUP} + 5.842,294 \text{ CUP} + 19.796,6 \text{ CUP} + 0 + 8.280 \text{ CUP}$$

$$CD = 80.657,244 \text{ CUP}$$

4.1.2 Cálculo del costo indirecto

El costo indirecto, se refiere a los gastos de electricidad consumida, de administración, instalaciones, entre otros; en el proceso de investigación. Se estima aplicando un coeficiente de gastos al salario básico de la investigación. El coeficiente de gastos para un Departamento Docente se estima en 0,84 y para una Unidad de Ciencia y Técnica (UCT) es 1,4063. Por tanto, el costo indirecto se obtiene mediante la ecuación:

$$CI = 1,4063 * SB \quad (4.8)$$

$$CI = 1,4063 * 42.843,85$$

$$CI = 60.251,306 \text{ CUP}$$

Cálculo del costo total

$$CT = 80.657,244 \text{ CUP} + 60.251,306 \text{ CUP}$$

$$CT = 140.908,55 \text{ CUP}$$

Es importante destacar que, el costo total y demás elementos calculados, presentan cifras tan elevadas con respecto a trabajos de diploma anteriores, debido al reordenamiento monetario llevado a cabo a partir de enero del año 2021.

4.2 Precio de los servicios científico-técnico y de los resultados de la investigación

Este gasto se refiere a lo que paga o pagaría según contrato la entidad que recibe el servicio. Según la Resolución Ministerial Conjunta del Comité Estatal de Precios y la Academia de Ciencias de Cuba el precio de los servicios o resultados será igual a la ecuación:

$$P = CT + (\text{hasta } 0,1) * CT \quad (4.9)$$

Dónde: P: Precio.

Se permite como ganancia hasta un 10% del costo total de la investigación en que se incurre. Esto debe estar avalado por copia del contrato o por carta de la entidad que recibe el servicio o resultado. A partir de un reajuste de la ecuación se obtiene el precio del servicio.

$$P = 1,1 * CT$$

$$P = 1,1 * 140.908,55 \text{ CUP}$$

$$P = 154.999,405 \text{ CUP}$$

$$P = 1.291,661 \text{ USD}$$

4.3 Análisis de la factibilidad e impacto de los resultados

Análisis económico

La implementación del detector de adulterantes diseñado en este trabajo presenta ventajas económicas significativas, en comparación con los costosos detectores de adulterantes utilizados en laboratorios que se analizaron en el epígrafe 1.8. Estos equipos requieren una inversión considerable tanto en la adquisición inicial como en el mantenimiento y calibración periódica, lo que limita su accesibilidad y uso generalizado. Por otro lado, el detector basado en el sensor AS7265X y la Raspberry Pi ofrecen una alternativa más asequible, ya que sus componentes son más económicos, su adquisición implica un menor costo inicial y no requiere el personal especializado para su manejo. La Raspberry Pi es capaz de alimentar y controlar el sensor, reduciendo la necesidad de equipos adicionales y costosos.

Además de los beneficios económicos, la implementación de este detector más accesible y eficiente promueve la accesibilidad y el uso generalizado en diversos contextos. Pequeñas y medianas empresas, así como comunidades rurales, pueden beneficiarse de este sistema de detección sin incurrir en gastos excesivos. Esto ayuda a fortalecer la cadena de suministro de la leche a nivel local, asegurando la calidad del producto y protegiendo a los consumidores de posibles riesgos para la salud. La facilidad de uso y la disponibilidad de estos detectores también fomentan su adopción por parte de instituciones gubernamentales y organismos reguladores, lo que contribuye a un monitoreo más efectivo y una aplicación más rigurosa de los estándares de calidad.

Impacto Social

La elaboración de un detector de adulterantes de bajo costo, no invasivo y con capacidad de mostrar resultados en tiempo real tiene un impacto social de gran relevancia en diversos aspectos. El fortalecimiento de la seguridad alimentaria es uno de los beneficios más destacados. La disponibilidad de un detector accesible y eficiente permite llevar a cabo pruebas de calidad de manera ágil, contribuyendo así a garantizar la inocuidad de los alimentos. Esto es

especialmente significativo en el caso de la leche y otros productos perecederos, donde la detección temprana de adulterantes es crucial para prevenir riesgos para la salud pública y disminuir la propagación de productos no seguros en el mercado.

Un aspecto relevante es la equidad y accesibilidad en el ámbito de la industria alimentaria. La creación de un detector permite que productores de menor escala o ubicados en regiones con recursos limitados puedan acceder a tecnología de control de calidad. Esto fomenta la equidad en el sector, al brindar a todos los actores, independientemente de su tamaño o ubicación, la posibilidad de asegurar la calidad de sus productos y competir en igualdad de condiciones en el mercado. Así, se promueve un ambiente de competencia justa y se refuerza la confianza de los consumidores en el mercado alimentario.

Aplicación para la Defensa

Las tecnologías de detección de adulterantes en alimentos desempeñan un papel fundamental en el ámbito de la defensa nacional de un país, como se muestra en los siguientes ejemplos:

- **Protección de la cadena de suministro:** En el contexto de defensa nacional, es fundamental garantizar la integridad de la cadena de suministro de alimentos. Un detector de adulterantes puede ser utilizado para verificar la autenticidad y calidad de los alimentos suministrados a las fuerzas militares y a la población en general. Esto ayuda a prevenir situaciones en las que los adversarios intenten debilitar la fuerza y la resistencia del país mediante la introducción de alimentos adulterados o contaminados.
- **Detección de sustancias nocivas:** Un detector de adulterantes en alimentos puede ser utilizado para identificar la presencia de sustancias nocivas o tóxicas que podrían ser utilizadas en actos de sabotaje o terrorismo alimentario. La capacidad de realizar pruebas rápidas y en tiempo real ayuda a detectar y mitigar riesgos potenciales, asegurando la protección de la población y la defensa de los intereses nacionales.

- **Identificación de amenazas biológicas:** En situaciones de emergencia o conflictos, un detector de adulterantes puede desempeñar un papel importante en la identificación de agentes biológicos o enfermedades, transmitidas por alimentos que puedan ser utilizados como armas biológicas. La detección temprana y precisa de estas amenazas permite tomar medidas rápidas para controlar su propagación y minimizar los efectos perjudiciales.
- **Control de la calidad de los alimentos en operaciones militares:** Durante las operaciones militares, es esencial garantizar la calidad y seguridad de los alimentos suministrados a las tropas desplegadas en zonas de conflicto. Un detector de adulterantes portátil y de bajo costo puede facilitar la realización de pruebas rápidas en el campo, para verificar la autenticidad de los alimentos y detectar posibles adulteraciones o contaminaciones, asegurando la salud y el bienestar de los soldados.

4.4 Conclusiones del Capítulo

La implementación del detector de adulterantes que se diseñó en este trabajo resulta una alternativa viable y factible económicamente, en comparación con los costosos detectores de adulterantes utilizados en laboratorios que se analizaron en el epígrafe 1.8. Estos equipos requieren una inversión considerable tanto en la adquisición inicial como en el mantenimiento y calibración periódica, lo que limita su accesibilidad y uso generalizado. Por otro lado, el detector basado en el sensor AS7265X y la Raspberry Pi ofrece una alternativa más asequible. Sus componentes son más económicos, su adquisición implica un menor costo inicial, no requiere el personal especializado para su manejo y tiene grandes apelaciones.

La asequibilidad y accesibilidad de este detector tienen un elevado impacto social, ya que permiten su adopción por parte de pequeñas y medianas empresas, así como de comunidades rurales con recursos financieros limitados. Esto fortalece la cadena de suministro de la leche a nivel local, garantizando la calidad del producto y protegiendo a los consumidores de riesgos para la salud asociados con adulterantes.

Además, puede contribuir a la defensa del país en aspectos como la protección de la cadena de suministro de alimentos, la detección de sustancias nocivas, la identificación de amenazas biológicas y el control de calidad de alimentos en operaciones militares. La capacidad del detector para verificar la autenticidad y calidad de los alimentos puede prevenir situaciones de sabotaje o terrorismo alimentario, salvaguardando la protección de la población y los intereses nacionales.

CONCLUSIONES GENERALES

A partir de la realización del presente trabajo de diploma, se logró implementar un sistema de medición de bajo costo para la detección de adulterantes en la leche empleando la SBC Raspberry Pi y el sensor espectroscópico AS7265x. La combinación del hardware, el firmware y la página web desarrollados ha creado un sistema integral que proporciona a los usuarios una experiencia interactiva y de fácil acceso. Con el uso de tecnologías como Python, Flask y herramientas de análisis de datos como PCA y LDA, se ha logrado un detector efectivo y adaptable para abordar el problema de adulteración en la leche. La asequibilidad y accesibilidad de este detector tienen un elevado impacto social, ya que permiten su adopción por parte de pequeñas y medianas empresas, así como de comunidades rurales con recursos financieros limitados.

A partir de lo expuesto anteriormente queda demostrado que:

- Se validó que la espectroscopia es una técnica altamente favorable para la construcción de un detector de adulterantes.
- El sensor AS7265X funciona correctamente en la detección de adulterantes y es una excelente opción por su relación costo beneficio.
- La Raspberry Pi posee la capacidad de procesamiento y almacenamiento necesaria para realizar el análisis de los datos capturados por el sensor, no siendo necesario el uso de una PC, lo que reduce el costo del equipo final y le otorga portabilidad. Este punto en especial es un aporte único de este trabajo respecto a los analizados en la búsqueda bibliográfica.
- La combinación de PCA y LDA en el proceso de análisis de los datos espectrales ha permitido obtener un modelo más robusto y preciso para la detección. Al reducir la dimensionalidad de los datos con PCA para resolver el problema de la colinealidad de los datos y luego aplicar LDA, se logra una representación más discriminativa y se mejora la separabilidad entre las clases, lo que aumenta la capacidad del sistema para identificar y clasificar correctamente las muestras.
- Al comparar los dos grupos distintos de muestras utilizadas para entrenar el sistema se determinó que las condiciones ambientales y los

elementos utilizados durante la adquisición de las muestras, pueden influir significativamente en la precisión y confiabilidad del detector diseñado. Al evitar la luz externa y utilizar un frasco opaco, se minimiza la posibilidad de interferencia y se logra una medición más precisa de los espectros de las muestras.

RECOMENDACIONES

A partir de los resultados obtenidos en este trabajo se recomienda tener en cuenta los siguientes aspectos en futuras investigaciones:

- Continuar el estudio de este tema, dado el alto nivel de impacto que representa.
- Ampliar el detector para otros adulterantes de la leche.
- Ampliar el detector para otros tipos de alimentos.
- Implementar en el sistema la posibilidad de seleccionar, antes de realizar la medición, distintas posibilidades de detección de múltiples adulterantes.
- Crear una interfaz de protección de acceso al equipo
- Estudiar la posibilidad de implementar el sistema de predicción en un microcontrolador ESP32.

REFERENCIAS BIBLIOGRÁFICAS

- [1] «Producción y productos lácteos: Productos». <https://www.fao.org/dairy-production-products/products/es/> (accedido 4 de junio de 2023).
- [2] I.-A. Potărniche y R.-V. Gălătuș, «Spectrometric Milk Analyzer», en *2021 IEEE 27th International Symposium for Design and Technology in Electronic Packaging (SIITME)*, oct. 2021, pp. 214-217. doi: 10.1109/SIITME53254.2021.9663432.
- [3] N. Sowmya y V. Ponnusamy, «Development of Spectroscopic Sensor System for an IoT Application of Adulteration Identification on Milk Using Machine Learning», *IEEE Access*, vol. 9, pp. 53979-53995, 2021, doi: 10.1109/ACCESS.2021.3070558.
- [4] «Nc 448. leche. especificaciones de calidad.» <https://www.slideshare.net/ceciliamoldes/nc-448-leche-especificaciones-de-calidad> (accedido 4 de junio de 2023).
- [5] A. Martínez Vasallo, A. Villoch Cambas, A. Ribot Enriquez, N. Montes de Oca, Y. Riverón Alemán, y P. Ponce Ceballo, «Calidad e inocuidad en la leche cruda de una cadena de producción de una provincia occidental de Cuba», *Rev. Salud Anim.*, vol. 37, n.º 2, pp. 79-85, ago. 2015.
- [6] «¿Cuál fue el origen de la agricultura?», *National Geographic*, 4 de enero de 2022. <https://www.nationalgeographic.es/historia/2022/01/cual-fue-el-origen-de-la-agricultura> (accedido 19 de mayo de 2023).
- [7] R. Aguilar *et al.*, «La ganadería en Cuba : desempeño y desafíos», 2004, Accedido: 4 de junio de 2023. [En línea]. Disponible en: <https://www.colibri.udelar.edu.uy/jspui/handle/20.500.12008/9463>
- [8] J. Rodríguez Huertas *et al.*, «Leche y productos lácteos como vehículos de calcio y vitamina D: papel de las leches enriquecidas», *Nutr. Hosp.*, vol. 36, n.º 4, pp. 962-973, ago. 2019, doi: 10.20960/nh.02570.
- [9] E. Fernández Fernández *et al.*, «Documento de Consenso: importancia nutricional y metabólica de la leche», *Nutr. Hosp.*, vol. 31, n.º 1, pp. 92-101, ene. 2015, doi: 10.3305/nh.2015.31.1.8253.

- [10] A. Escobar, R. Faure, D. Sosa, P. Ponce, y S. Vega, «MELAMINA. UN PROBLEMA POTENCIAL PARA LA SALUD ANIMAL Y HUMANA COMO ADULTERANTE EN LOS ALIMENTOS CON ÉNFASIS EN LA LECHE», *Rev. Salud Anim.*, vol. 32, n.º 1, pp. 22-31, abr. 2010.
- [11] M. M. Gritsenko, E. A. Nazarova, P. V. Krivoschapkin, y E. F. Krivoschapkina, «Titanium dioxide-based optical sensors for detecting milk adulteration», *J. Food Compos. Anal.*, vol. 120, p. 105335, jul. 2023, doi: 10.1016/j.jfca.2023.105335.
- [12] Ingenierizando, «▷ ¿Qué es la ley de Beer-Lambert? (fórmula y aplicaciones)», *Ingenierizando*, 22 de julio de 2022. <https://www.ingenierizando.com/optica/ley-de-beer-lambert/> (accedido 4 de junio de 2023).
- [13] M.-T. I. I. all rights reserved, «Espectroscopia ultravioleta-visible: conceptos básicos». https://www.mt.com/es/es/home/applications/Application_Browse_Laboratory_Analytics/uv-vis-spectroscopy/uvvis-spectroscopy-explained.html (accedido 4 de junio de 2023).
- [14] «Qué es y cómo funciona la tecnología NIR», 3 de octubre de 2022. <https://www.tecnilab.es/espectrometria-nir-laboratorio/> (accedido 19 de mayo de 2023).
- [15] M. Habibullah *et al.*, «Low-Cost Multispectral Sensor Array for Determining Leaf Nitrogen Status», *Nitrogen*, vol. 1, n.º 1, Art. n.º 1, sep. 2020, doi: 10.3390/nitrogen1010007.
- [16] M. M. N. Shahrabani y S. B. Mansor, «Calibration And Testing A Low-Cost Spectrometer For Ground Measurement Mustafa», vol. 9, n.º 09, 2020.
- [17] L. A. Infantes Otero, «Aplicación de la espectroscopia THz en el Análisis no Invasivo de Alimentos: Una revisión», *Univ. Nac. Front.*, abr. 2022, Accedido: 8 de abril de 2023. [En línea]. Disponible en: <http://repositorio.unf.edu.pe/handle/UNF/133>

- [18] Y. Velásquez, R. Ventura, M. Villarreal, y A. Campos, «Detección de la adulteración de la leche mediante sensor óptico», *Rev. Iniciación Científica*, vol. 7, ago. 2021, doi: 10.33412/rev-ric.v7.0.3248.
- [19] A. S. Ivanova, A. D. Merkulova, S. V. Andreev, y K. A. Sakharov, «Method for determination of hydrogen peroxide in adulterated milk using high performance liquid chromatography», *Food Chem.*, vol. 283, pp. 431-436, jun. 2019, doi: 10.1016/j.foodchem.2019.01.051.
- [20] «Amazon.com: Ultrasonic Milk Analyzer Ekomilk Bond Total: Industrial & Scientific». <https://www.amazon.com/Ultrasonic-Analyzer-Ekomilk-Bond-Total/dp/B089QB5BVY> (accedido 4 de junio de 2023).
- [21] «Amazon.com: Ekomilk Ultra 40S Ultrasonic Milk Analyzer: Industrial & Scientific». https://www.amazon.com/dp/B0914GTPQ5/ref=aod_recs_desktop_prsubs_0 (accedido 4 de junio de 2023).
- [22] «Amazon.com: Lactoscan Milk analyzers: Industrial & Scientific». <https://www.amazon.com/AjantaExports-Lactoscan-Milk-analyzers/dp/B0946DGXQ4> (accedido 4 de junio de 2023).
- [23] «Hiyi - Julie X High Accurate And Is Fully Automatic Dairy Milk Analyzer - Buy Pasteurized Soy Milk Analyzer,Milk Fat Milk Analyzer,Ultrasonic Milk Analyzer Product on Alibaba.com». https://www.alibaba.com/product-detail/HiYi-Julie-X-High-accurate-and_1600230006309.html?spm=a2700.details.0.0.6b4113435H0err (accedido 4 de junio de 2023).
- [24] hmong.wiki, «Computadora de placa única HistoriayAplicaciones». https://hmong.es/wiki/Single_board_computer (accedido 21 de mayo de 2023).
- [25] «Melopero Raspberry Pi 3 Model B, CPU Quad Core 1,2GHz Broadcom BCM2837 64bit , 1GB RAM, WiFi, Bluetooth BLE, plata: Amazon.es: Informática». <https://www.amazon.es/Raspberry-Pi-Modelo-Quad-Core-Cortex-A53/dp/B01CD5VC92> (accedido 21 de mayo de 2023).

[26] «Raspberry Pi 3 Model B+ - Placa base Raspberry Raspberry en LDLC». <https://www.ldlc.com/es-es/ficha/PB00246555.html> (accedido 21 de mayo de 2023).

[27] «AS7265X pdf, AS7265X Description, AS7265X Datasheet, AS7265X view :: ALLDATASHEET »: <https://pdf1.alldatasheet.com/datasheet-pdf/view/1244817/AMSCO/AS7265X.html> (accedido 19 de mayo de 2023).

[28] «¿Qué es Python y para qué se usa? Guía para principiantes», *Coursera*, 17 de mayo de 2023. <https://www.coursera.org/mx/articles/what-is-python-used-for-a-beginners-guide-to-using-python> (accedido 21 de mayo de 2023).

[29] «Qué es Flask y ventajas que ofrece», *OpenWebinars.net*, 17 de noviembre de 2017. <https://openwebinars.net/blog/que-es-flask/> (accedido 21 de mayo de 2023).

[30] M. P. Callao y I. Ruisánchez, «An overview of multivariate qualitative methods for food fraud detection», *Food Control*, vol. 86, pp. 283-293, abr. 2018, doi: 10.1016/j.foodcont.2017.11.034.

[31] J. A. M. García y I. A. Uribe, «Técnicas para detección de outliers multivariantes».

[32] S. X. Wu, H.-T. Wai, L. Li, y A. Scaglione, «A Review of Distributed Algorithms for Principal Component Analysis», *Proc. IEEE*, vol. 106, n.º 8, pp. 1321-1340, ago. 2018, doi: 10.1109/JPROC.2018.2846568.

[33] D. Pelliccia, «The cricket thermometer: an introduction to Principal Component Analysis in Python A worked example for an introduction to Principal Component Analysis in Python.», 21 de marzo de 2017. <https://nirpyresearch.com/cricket-thermometer-intro-pca-python/> (accedido 14 de mayo de 2023).

[34] D. Pelliccia, «Classification of NIR spectra using Principal Component Analysis in Python», 23 de marzo de 2018. <https://nirpyresearch.com/classification-nir-spectra-principal-component-analysis-python/> (accedido 11 de mayo de 2023).

- [35] A. Kumar, «Feature Selection vs Feature Extraction: Machine Learning», *Data Analytics*, 24 de marzo de 2023. <https://vitalflux.com/machine-learning-feature-selection-feature-extraction/> (accedido 5 de junio de 2023).
- [36] T. Kurita, «Principal Component Analysis (PCA)», en *Computer Vision: A Reference Guide*, Cham: Springer International Publishing, 2019, pp. 1-4. doi: 10.1007/978-3-030-03243-2_649-1.
- [37] S. Ibrahim, S. Nazir, y S. A. Velastin, «Feature Selection Using Correlation Analysis and Principal Component Analysis for Accurate Breast Cancer Diagnosis», *J. Imaging*, vol. 7, n.º 11, Art. n.º 11, nov. 2021, doi: 10.3390/jimaging7110225.
- [38] «ML | Análisis Discriminante Lineal – Barcelona Geeks». <https://barcelonageeks.com/ml-analisis-discriminante-lineal/> (accedido 5 de junio de 2023).
- [39] S. D. Fabiyi *et al.*, «Comparative Study of PCA and LDA for Rice Seeds Quality Inspection», en *2019 IEEE AFRICON*, Accra, Ghana: IEEE, sep. 2019, pp. 1-4. doi: 10.1109/AFRICON46755.2019.9134059.
- [40] M. Esteki, Z. Shahsavari, y J. Simal-Gandara, «Use of spectroscopic methods in combination with linear discriminant analysis for authentication of food products», *Food Control*, vol. 91, pp. 100-112, sep. 2018, doi: 10.1016/j.foodcont.2018.03.031.
- [41] A. Kumar, «PCA vs LDA Differences, Plots, Examples», *Data Analytics*, 13 de abril de 2023. <https://vitalflux.com/pca-vs-lda-differences-plots-examples/> (accedido 14 de mayo de 2023).
- [42] D. Pelliccia, «Classification of NIR spectra by Linear Discriminant Analysis in Python», 3 de diciembre de 2018. <https://nirpyresearch.com/classification-nir-spectra-linear-discriminant-analysis-python/> (accedido 14 de mayo de 2023).

BIBLIOGRAFÍA CONSULTADA

- [1] W. Harrington, *Learning Raspbian*, 2ª ed. Reino Unido: Packt Publishing Ltd, 2016.
- [2] E. Matthes, *Python Crash Course: A Hands-On, Project-Based Introduction to Programming*, 2nd ed., No Starch Press, 2019.
- [3] A. Papoulis and S. U. Pillai, *Probability, Random Variables and Stochastic Processes*, 4th ed. McGraw-Hill Education, 2017.
- [4] J.R. Ferraro, L.J. Basile, and B.S. Brunshawig, *Introduction to Spectroscopy*, 5th ed., Cengage Learning, 2019.
- [5] C. M. Weaver, *Dairy in Human Health and Disease Across the Lifespan*, Academic Press, 2018.